Universidade Federal do Paraná

Lucas Scheffer

Agrupamento por Vetores de Suporte: fundamentos e aplicações

Curitiba
2025

Lucas Scheffer

Agrupamento por Vetores de Suporte: fundamentos e aplicações

Trabalho de Conclusão de Curso apresentado à disciplina Laboratório B do Curso de Graduação em Estatística da Universidade Federal do Paraná, como exigência parcial para obtenção do grau de Bacharel em Estatística.

Orientador: Prof. Dr. Anderson Ara

Curitiba
2025

Agradecimentos

Gostaria de agradecer a todos que participaram direta ou indiretamente deste trabalho, principalmente ao meu orientador Prof. Dr. Anderson Ara, que me deu embasamento teórico e computacional muito poderoso para realizá-lo. Ao Prof. Dr. Paulo Justiniano Ribeiro Júnior, que me ajudou na otimização do código e forneceu inúmeras ideias para que isso fosse possível.

Também gostaria de agradecer à minha família. Ao meu pai Jorge Scheffer, minha mãe Ana Paula Scheffer, meu irmão Leonardo Scheffer e minha namorada Camilly, por todo o apoio, companheirismo e compreensão neste momento crucial de minha formação.

"Ouvi reiteradamente a seguinte afirmação: teorias complexas não funcionam; algoritmos simples sim. (...) Pelo menos nos problemas de inferência estatística isso não é verdade. Gostaria de demonstrar que na área da ciência é válido um bom e velho princípio: nada é mais prático do que uma boa teoria.".

(Vladmir Vapnik)

Resumo

A análise de agrupamento é uma tarefa do aprendizado não supervisionado que possui diversas características a serem exploradas, desde vários métodos até inúmeras métricas de validação. Neste trabalho, estudamos como o agrupamento por vetores de suporte interage com os dados, quais padrões este método consegue identificar e uma comparação com os métodos *k-means*, *fuzzy c-means*, agrupamento hierárquico, *self-organizing map* e DBSCAN. Técnicas que envolvem o cálculo de distâncias euclidianas ou que dependem de uma base de dados linearmente divisível tendem a se equivocar quando são utilizados com dados não lineares. Para esse tipo de dado, o agrupamento por vetores de suporte surge como um método muito forte a fim de superar os desafios apresentados. Os resultados obtidos a partir de estudos de simulação e aplicações em bases reais nos comprovaram que o SVC supera, na grande maioria das vezes, os agrupamentos clássicos, como k-means e agrupamento hierárquico. Entretanto, ainda são necessários mais estudos, principalmente no âmbito computacional, para melhoria de performance da função e otimização do parâmetro σ.

Palavras-chave: Agrupamento; Aprendizado de máquina; Vetores de suporte.

Abstract

Cluster analysis is an unsupervised learning task with a lot of features to be explored, since different methods to countless validation metrics. In this work, we study how the support vector clustering interact with data, which patterns this method can identify and a comparison with k-means, fuzzy c-means, clustering trees, self-organizing map and DBSCAN. Techniques based on Euclidean distances or that depend on a linearly divisible database tend to fail when used with non-linear data. For this type of data, support vector clustering emerges as a very strong method to overcome the challenges presented. The results obtained from simulation studies and real data applications prove that SVC outperforms, in most cases, classical clustering, such as k-means and clustering trees. However, further studies are still needed, mainly in the computational field, to improve the performance of the function and optimize the parameter σ.

Keywords: Clustering; Machine Learning; Support Vectors.

Lista de abreviaturas e siglas

SVC	*Support Vector Clustering*
RFM	*Recency, Frequecy and Monetary*
SVM	*Support Vector Machines*
ARI	*Adjusted Rand Index*
SOM	*Self-organizing map*

Lista de ilustrações

Figura 1 – *Smile* com rótulos originais 24
Figura 2 – Agrupamentos da base *Smile* 25
Figura 3 – *Two rings* com rótulos originais 26
Figura 4 – Agrupamentos da base *Two Rings* 27
Figura 5 – *Two Moons* com rótulos originais 28
Figura 6 – Agrupamentos da base *Two Moons* 29
Figura 7 – *Noisy data* com rótulos originais 30
Figura 8 – Agrupamentos da base *noisy data* 31
Figura 9 – *Two moons* 3D 32
Figura 10 – Agrupamentos para *Two moons* 3D 33
Figura 11 – DBSCAN para *Two moons* 3D 34
Figura 12 – SVC para *Two moons* 3D 35
Figura 13 – Base *banknotes* 36
Figura 14 – t-SNE aplicado a *banknotes authentication* 37
Figura 15 – Agrupamentos em *banknotes authentication* 38
Figura 16 – Agrupamentos em *walking activity* 39
Figura 17 – Agrupamentos em *walking activity* 3D 40
Figura 18 – Capitais do Brasil 41
Figura 19 – Agrupamentos das capitais do Brasil 42

Lista de tabelas

Tabela 1 – Métricas para *Smile* 25
Tabela 2 – Métricas para *Two Rings* 27
Tabela 3 – Métricas para *Two moons* 29
Tabela 4 – Métricas para *noisy data* 31
Tabela 5 – Métricas para *two moons* 3D 35
Tabela 6 – Métricas para *banknotes authentication* 38
Tabela 7 – Métricas para *walking activity* 41
Tabela 8 – Métricas para capitais do Brasil 43

Sumário

Lista de ilustrações 7

Lista de tabelas 8

1 INTRODUÇÃO 11

2 METODOLOGIA 14
2.1 Máquinas de vetores de suporte 14
2.2 Agrupamento por vetores de suporte 14
2.3 Definição de agrupamentos 16

3 OUTROS MÉTODOS DE AGRUPAMENTO E MÉTRICAS DE VALIDAÇÃO 18
3.1 *K-means* 18
3.2 Agrupamento hierárquico 18
3.3 DBSCAN 19
3.4 *Fuzzy C-means* 20
3.5 *Self-organizing maps* 20
3.6 Métricas de avaliação 21
3.6.1 Validação interna 21
3.6.1.1 Índice de Dunn 21
3.6.1.2 Silhueta 22
3.6.2 Validação externa 22
3.6.2.1 Índice de Rand corrigido 23

4 RESULTADOS E DISCUSSÃO 24
4.1 Aplicação em dados artificiais 24
4.1.1 *Smile* 24
4.1.2 *Two rings* 26
4.1.3 *Two Moons* 27
4.1.4 *Noisy data* 30
4.1.5 *Two moons* em três dimensões 32
4.2 Aplicação em dados reais 36
4.2.1 *Banknote Authentication* 36
4.2.2 *User identification from walking activity* 38
4.2.3 Capitais do Brasil 41

5 CONSIDERAÇÕES FINAIS 44

REFERÊNCIAS BIBLIOGRÁFICAS 46

1 Introdução

Atualmente, as empresas precisam tomar decisões de forma rápida e assertiva. Em um mundo cada vez mais conectado, decidir por medidas baseadas em senso comum já não é mais uma opção viável. Uma decisão errada pode ocasionar perda de tempo e dinheiro, algo que nenhuma companhia deseja. Dentro das empresas, são gerados milhares de dados, em várias fontes e diversos formatos. Urge a necessidade de tratá-los e transformá-los em informação, porém, sem os instrumentos necessários, lidar com eles se torna uma tarefa complicada. Para enfrentar esses obstáculos, a Ciência de Dados surge como uma ferramenta poderosa que auxilia na tomada de decisão e busca contornar esses revezes, atuando nas mais diversas áreas. Neste contexto, o aprendizado de máquina aparece como uma área de grande importância que auxilia a lidar com essas questões.

Dentro dessa área, temos o aprendizado supervisionado e o não supervisionado. A grosso modo, o primeiro lida com problemas nos quais existem rótulos de entrada, que nos ajudam a construir os modelos para fins de predição (IZBICKI; SANTOS, 2020). Geralmente, definem-se bases de treino e teste, sendo a primeira para treinar o modelo, e a segunda para verificar sua acurácia na tarefa que foi designada a ele. Já o não supervisionado não recebe os rótulos como variável de entrada. Ele serve para descrever padrões intrínsecos à base, fornecendo informações sobre como eles se comportam. Inclusive, podemos pensar que a saída dos métodos não supervisionados pode ser utilizada como rótulos para métodos supervisionados. Muitas técnicas de aprendizado de máquina foram desenvolvidas dentro dessas duas categorias: modelos de predição, agrupamento, classificação, redução de dimensionalidade, sistema de recomendação, etc (FERREIRA; ZEVIANI, 2013).

Neste trabalho, estudaremos a análise de agrupamento, que tem como principal objetivo juntar dados mais parecidos que outros em grupos. Os integrantes desses grupos devem ter características parecidas, para que a análise de agrupamento faça sentido. O algoritmo visa dividir os dados em grupos menores, em que dados pertencentes a um mesmo agrupamento possuem as mesmas propriedades. Dentro do contexto do mundo corporativo, podemos pensar na *clusterização* como um grande auxiliador na tomada de decisão e uma poderosa ferramenta de observação de padrões. Ela traz diversos benefícios, por exemplo, direção para ações de marketing, identificação dos melhores clientes ou melhores itens, observação de consumidores com padrões parecidos, entre outros. Todos eles ajudam a empresa a descobrir onde e como agir, visto que reduzem a massa de dados para grupos menores, o que também otimiza o tempo e os recursos empregados nas estratégias adotadas. Afinal, direcionar esforços para todo o público demanda mais investimento de tempo e dinheiro do que focar em grupos específicos, com comportamentos semelhantes. Assim sendo, a análise de agrupamento fornece mais assertividade e eficiência, além de reduzir o desperdício de recursos.

Existem dois tipos de agrupamento: *soft* e *hard clustering* (PETRUS et al., 2019). O primeiro permite que uma observação esteja em mais de um grupo, possuindo uma probabilidade associada de pertencimento. Para este caso, utilizaremos o *fuzzy c-means*. Já no segundo tipo temos que uma observação está atrelada a somente um grupo, sem níveis de pertencimento. Para este caso, utilizaremos *k-means, SOM*, DBSCAN, agrupamento hierárquico e o SVC.

Existem várias técnicas de agrupamento conhecidas, com aplicações nas mais diversas áreas. Rajagopal (2011) utilizou o *IBM Intelligent Miner tool* com o processo de agrupamento demográfico, visto que ele funciona melhor com dados contínuos do que o processo de agrupamento neural. Foram definidos o número máximo de grupos como quatro após estudarem a base de dados e como eles se distribuem. Já Kansal et al. (2018) estudou aplicações do *k-means*, agrupamento aglomerativo e agrupamento por deslocamento médio em uma base de clientes de uma loja de varejo local, utilizando o método do cotovelo para definição do número otimizado de grupos. Christodoulakis (2005) usou a análise da matriz RFM (*Recency, Frequency and Monetary*) a fim de criar pontuações para os clientes com base em três critérios previamente calculados: frequência de compra, recência e valor monetário. Também se utilizou do princípio de Pareto para entender quais são os melhores clientes. Este princípio nos diz que, idealmente, 20% dos clientes devem representar 80% do faturamento total da empresa, ou seja, buscavam identificar quem eram esses consumidores. Após o cálculo dos valores da matriz RFM, utilizou o método *k-means* e o agrupamento de duas etapas, que utiliza fundamentos de agrupamento hierárquico para chegar ao resultado esperado e comparou os resultados dos dois métodos.

As técnicas mais tradicionais de agrupamento possuem limitações, que serão exploradas posteriormente. Uma limitação tem relação com o formato que os dados têm. Algoritmos como *k-means* ou agrupamento hierárquico não conseguem lidar bem com grupos de formatos não convexos, pois sempre consideram que os dados são linearmente separáveis, o que pode gerar resultados inadequados. Outro ponto de atenção tem relação com a presença de *outliers* na base, que acabam afetando muito a *clusterização* dos métodos mais tradicionais. Segundo Huang et al. (2007), o SVC consegue superar facilmente essas dificuldades apresentadas, tornando-o um método alternativo quando lidamos com bases de dados com formatos não convexos e com a presença de muitos *outliers*.

A técnica que será explorada nesse trabalho é o Agrupamento por Vetores de Suporte (SVC), proposta por Ben-Hur et al. (2001). Ela se embasa a partir da teoria atrelada às máquinas de vetores de suporte (SVM), conhecidas por seu uso em tarefas de classificação. O SVC é um algoritmo não paramétrico que computa vários contornos em volta dos dados, produzindo, assim, agrupamentos. Para o mapeamento de dados, ele necessita do uso de um núcleo para realizar os cálculos, e, neste trabalho, utilizaremos o núcleo gaussiano, com formato $K(x_i, x_j) = e^{-\sigma||x_i - x_j||^2}$.

Chiang e Hao (2003) propõe o SVC com o cálculo de várias esferas, identificando

regiões densas no espaço original e encontrando suas esferas no espaço de características, minimizando o raio delas. Para verificar a eficácia desse método, realizam uma aplicação para agrupar imagens de dígitos manuscritos, obtendo sucesso. Já Huang et al. (2007) aplicou o método para agrupar clientes de uma companhia de bebidas, comparando-o com o *k-means* e *self-organizing feature maps*, concluindo que o SVC foi o melhor. Bagci e Karal (2020) testou o agrupamento com os núcleos gaussiano, cauchy e laplaciano na base de dados Iris e em um teste de simulação, identificando o *kernel* laplaciano como o melhor, para estes exemplos. Pham et al. (2017) trabalhou na aceleração do método por meio da aplicação do *stochastic gradient descent* para encontrar o domínio da borda dos grupos, e também utilizou o cálculo de um ponto de equilíbrio para realizar a identificação dos *clusters*, obtendo um método mais rápido que o SVC original.

Neste sentido, buscou-se responder os seguintes questionamentos: como o agrupamento por vetores de suporte interage com os dados? Ele supera os métodos *k-means*, agrupamento hierárquico, *self-organizing maps*, *fuzzy c-means* e DBSCAN? Quais são os valores das métricas de validação índice de Dunn, índice de Rand corrigido e silhueta? Quais resultados cada método produziu e qual foi o de melhor desempenho? Quais desafios foram encontrados ao implementar o agrupamento por vetores de suporte na linguagem R?

Espera-se ao final da investigação sinais positivos de que o agrupamento por vetores de suporte seja superior aos outros métodos testados, e que sua implementação no R esteja bem otimizada, pronta para uso em bases de dados de grande dimensão.

Este trabalho está organizado na seguinte forma. No Capítulo 2 encontra-se a metodologia utilizada. No Capítulo 3 está um estudo sobre os métodos *k-means*, agrupamento hierárquico, DBSCAN, *Fuzzy C-means* e *Self-Organizing Maps*, que serão utilizados para comparação com o SVC, e também das métricas índice de Dunn, índice de Rand corrigido e silhueta, que servirão para metrificar a qualidade de cada agrupamento. No Capítulo 4 estão os resultados e comparações do agrupamento por vetores de suporte com os demais métodos, aplicando-os tanto em bases de dados provenientes de simulação quanto reais. O Capítulo 5 exibe as conclusões, comentários finais e dificuldades encontradas na implementação do SVC na linguagem R, bem como pontos de melhoria, além de sugestões para trabalhos futuros.

2 Metodologia

2.1 Máquinas de vetores de suporte

O método máquinas de vetores de suporte (SVM) foi desenvolvido por Cortes e Vapnik (1995) e inicialmente para tarefas de classificação. Seu objetivo é maximizar a distância entre um hiperplano e alguns pontos, chamados de vetores de suporte. Utiliza propriedades geométricas para definir um hiperplano ótimo que separa o conjunto de dados, formando assim duas regiões. Os pontos que estão em uma região A são classificados como A, e os pontos que estão em uma região B como B. SVM consegue lidar com casos nos quais os dados são não linearmente separáveis e com casos em que há ruído na base de dados (STITSON et al., 1996).

As máquinas de vetores de suporte trabalham com a aplicação de um núcleo (*kernel*). Quando executam essa aplicação, ocorre um mapeamento não linear do espaço de entrada para o espaço de dados *kernelizado*, o que nos permite construir hiperplanos lineares no espaço de dados *kernelizado* e não lineares para o espaço de entrada dos dados.

Com o passar dos anos, o SVM se tornou uma técnica muito utilizada pela sua sólida teoria, que embasa fortemente seus resultados, tornando-se uma referência em problemas de classificação (DIBIKE; VELICKOV; SOLOMATINE, 2000). Por conta disso, algumas adaptações foram feitas para que, utilizando-se dos cálculos por trás do SVM, outras tarefas também fossem realizadas.

Uma variante do SVM bastante conhecida é o *support vector regression* (SVR), proposta em Vapnik, Golowich e Smola (1996). Enquanto o primeiro método busca maximizar as margens entre as classes, este procura minimizar os erros da regressão, dentro de um limite determinado por ϵ.

O *one-class* SVM é utilizado para detecção de *outlier*, tendo apenas a informação de uma classe. Ele constrói uma hiperesfera no espaço de dados *kernelizado* e a minimiza, a fim de identificar esses pontos aberrantes (MOURÃO-MIRANDA et al., 2011).

Temos também o *support vector density estimation* (SVDE) que é uma forma diferente para estimação da densidade de variáveis aleatórias, utilizando uma abordagem de otimização convexa (WESTON et al., 1999).

2.2 Agrupamento por vetores de suporte

O método de agrupamento por vetores de suporte foi desenvolvido em 2001 em Ben-Hur et al. (2001). O SVC, diferentemente do SVM, busca definir uma hiperesfera no espaço de dados *kernelizado*, para conseguir agrupar os dados do espaço de entrada, a fim

de identificar grupos com características em comum.

O espaço de dados *kernelizado* é, a grosso modo, o espaço dos dados originais após a aplicação do *kernel*, que aumenta a dimensão deles, passo fundamental para encontrar os vetores de suporte e realizar a *clusterização*.

Agrupamentos como *k-means* e hierárquico possuem dificuldades ao agrupar corretamente bases de dados que possuem formatos não convexos. Esses dados são caracterizados por não possuírem retas ou planos que os dividam de forma eficiente. Para este caso, o SVC surge com uma forma de atuação diferente dos métodos tradicionais, conseguindo superar essas dificuldades.

Segundo Huang et al. (2007), o agrupamento por vetores de suporte é uma boa técnica de agrupamento, principalmente nos casos em que os dados são não linearmente separáveis. Essa característica se dá pela aplicação do núcleo aos dados e pela utilização do espaço de dados *kernelizado*. Por isso, em uma seção à frente, estudaremos aplicações do método em algumas bases de dados que são não linearmente separáveis, e mostraremos as dificuldades que os métodos baseados em distâncias euclidianas possuem ao agrupá-los.

Indo para os cálculos atrelados ao método, primeiramente determinamos uma hiperesfera

$$||\phi(X_i) - a||^2 \leq R^2, \, \forall i = 1, 2, ..., n,$$

sendo ϕ uma transformação não linear,X_i os dados ,a o ponto central da hiperesfera, e R seu raio. Nesse problema, precisamos minimizar R

$$\min_{R,a} R^2.$$

Precisamos também pensar em pontos de dados que, mesmo após todos os cálculos e otimizações, se encontrarão fora dos limites dos agrupamentos. Para incorporar isso, precisamos definir uma variável de folga ξ e também uma constante de penalização C, adicionando mais constantes na minimização acima delimitada:

$$\min_{R,a,\xi} R^2 + C \sum_i \xi_i.$$

A equação da hiperesfera é dada por:

$$||\phi(X_i) - a||^2 \leq R^2 + \xi_i, \, \forall i = 1, 2, ..., n,$$
$$\xi_i \geq 0, \, \forall i = 1, 2, ..., n.$$

Podemos perceber que neste problema temos duas restrições, o que nos permite utilizar dois multiplicadores de Lagrange μ e β da seguinte forma:

$$L(R, a, \xi, \beta, \mu) = R^2 + C \sum_i \xi_i - \sum_i \beta_i (R^2 + \xi_i - ||\phi(X_i) - a||^2) - \sum_i \xi_i \mu_i,$$

com β, $\mu \geq 0$. É necessário encontrar os pontos de mínimo e de máximo da função, então vamos derivar em relação a R, a e ξ, respectivamente, e igualar a 0:

$$\nabla_R L = 0 \rightarrow \sum_i \beta_i = 1.$$
$$\nabla_a L = 0 \rightarrow a = \sum_i \beta_i \phi(X_i).$$
$$\nabla_\xi L = 0 \rightarrow \beta_i = C - \mu_i.$$

Então, podemos reduzir o problema levando em conta as condições que encontramos acima

$$\hat{L}(\beta) = (R^2 + C\sum_i \xi_i - \sum_i \beta_i(R^2 + \xi_i - ||\phi(X_i) - a||^2) - \sum_i \xi_i \mu_i) =$$

$$= R^2\left(1 - \sum_{i=1}^{n} \beta_i\right) + \sum_{i=1}^{n} \xi_i(C - \mu_i - \beta_i) + \sum_{i=1}^{n} \beta_i\left(||\phi(X_i) - a||^2\right) =$$

$$= R^2\big(1 - 1\big) + \sum_{i=1}^{n} \xi_i(\beta_i - \beta_i) + \sum_{i=1}^{n} \beta_i\left(||\phi(X_i) - a||^2\right) =$$

$$= \sum_{i=1}^{n} \beta_i\left(||\phi(X_i) - a||^2\right) =$$

$$= \sum_{i=1}^{n} \beta_i\left(||\phi(X_i)||^2 - 2a\phi(X_i) + ||a||^2\right) =$$

$$= \sum_{i=1}^{n} \beta_i\left(||\phi(X_i)||^2 - 2\sum_{j=1}^{n} \beta_j \phi(X_j)\phi(X_i) + ||\sum_{j=1}^{n} \beta_j \phi(X_j)||^2\right) =$$

$$= \sum_{i=1}^{n} \beta_i \phi(X_i)\phi(X_i) - \sum_{i,j=1}^{n} \beta_i \beta_j \phi(X_i)\phi(X_j).$$

Uma vez que $K(x_i, x_j) = \phi(x_i)\phi(x_j)$ é a função do núcleo (*kernel*). Neste trabalho utilizaremos o núcleo gaussiano que tem função $K(x_i, x_j) = e^{-\sigma||x_i - x_j||^2}$, com σ sendo um hiperparâmetro de tamanho do agrupamento (BEN-HUR et al., 2001). É importante ressaltar também que a hiperesfera é calculada já no espaço de dados *kernelizado*, com a aplicação do núcleo. Podemos notar que isso ocorre por conta do uso da transformação não linear $\phi(X_j)$.

2.3 Definição de agrupamentos

Após a definição do raio R da hiperesfera, segmentos de reta são traçados entre todos os pares de pontos, no espaço dos dados. Quando aplicamos o núcleo novamente, validamos se algum ponto desses segmentos passa dos limites da hiperesfera. Se passar,

os dois pontos conectados pelo segmento não estão no mesmo agrupamento. Ou seja, os pontos X_i e X_j estão no mesmo *cluster* se:

$$||\phi(tX_i + (1-t)X_j) - a||^2 < R^2, \forall t \in (0,1),$$

sendo t a posição ao longo do segmento. Originalmente, deveríamos verificar todo o segmento, mas isso é inviável computacionalmente, então selecionamos uma amostra de t entre 0 e 1, e vamos verificando ponto a ponto desse segmento.

A interpretação que pode ser feita desse processo é a de que, se o segmento entre dois pontos ultrapassa a hiperesfera, no espaço dos dados ele passa por locais com pouca densidade de pontos, o que pode nos remeter à ideia de que os pontos estão em grupos separados.

3 Outros métodos de agrupamento e métricas de validação

Nesse trabalho, iremos comparar os resultados obtidos no agrupamento de vetores de suporte com outras cinco técnicas bastante conhecidas de agrupamento: *k-means*, agrupamento hierárquico, *DBSCAN*, *fuzzy c-means* e *self-organizing maps*.

Existem várias métricas de avaliação de modelos de agrupamento, mas nesse trabalho nos limitaremos a utilizar três: índice de Rand corrigido, índice de Dunn e silhueta.

3.1 *K-means*

O *k-means* é uma técnica de *hard clustering* amplamente utilizada, possuindo aplicações nas mais diversas áreas (AHMED; SERAJ; ISLAM, 2020). Proposto em Forgy (1965), seu algoritmo é relativamente simples quando comparado com outras metodologias, mas ainda é uma das principais técnicas usadas.

1. Primeiramente definimos o número k de grupos e sorteamos k centroides;
2. Calcula-se a distância euclidiana de cada ponto até o centro do agrupamento;
3. Reagrupam-se os dados novamente e chegam em um novo centro;
4. Repete-se esse processo até que se chegue em uma resposta ótima.

Para definir o número de agrupamentos, podemos utilizar o método do cotovelo, construindo um *scree plot*, que mostra a relação entre a métrica *Within Sum of Squares* (WSS) e o número k de grupos, a fim de identificar o menor valor de k com o menor WSS. A partir do momento que, conforme k aumenta, o WSS não apresenta uma redução drástica, encontramos o melhor número de agrupamentos.

Porém, o método possui algumas limitações. Segundo Huang et al. (2007), o algoritmo não é bom para agrupamentos com formatos não lineares, além de que é muito influenciável por dados aberrantes (*outliers*), que podem distorcer os cálculos e, consequentemente, os resultados da pesquisa.

3.2 Agrupamento hierárquico

Outra técnica que será utilizada para comparação com o agrupamento por vetores de suporte é o agrupamento hierárquico, também de *hard clustering* (JOHNSON, 1967).

Este método é uma estrutura que representa a organização hierárquica dos dados em grupos com base em suas similaridades. Calcula-se as distâncias entre cada par de pontos. Os dois pontos mais próximos são fundidos em um agrupamento, progredindo até que todos os pontos estejam no mesmo *cluster*. De acordo com Blockeel e Ramon (2000), é uma árvore de decisão na qual cada nó é um grupo e cada folha é um dado individual. Nessa mesma analogia, a altura dos ramos simboliza a dissimilaridade entre os grupos definidos. Podemos escolher o número de agrupamentos apenas observando o dendrograma criado pela árvore ou utilizando também o método do cotovelo, explicado na seção anterior.

Assim como o *k-means*, o método também possui limitações. Dentre elas, sensibilidade a ruído, não lida bem com bases de dados não linearmente separáveis e possui baixa escalabilidade.

3.3 DBSCAN

O DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) é um método de agrupamento baseado na densidade, proposto por Ester et al. (1996). O objetivo do algoritmo é que, para cada dado, a vizinhança em um raio (determinado *a priori*) deve conter pelo menos um número mínimo de pontos (KHAN et al., 2014). Diferentemente do *k-means* e do agrupamento hierárquico, para este método não precisamos informar o número de grupos que queremos, pois, durante os cálculos, ele mesmo define isso por meio de otimização. O algoritmo é dado por:

- Definimos um ϵ e um mínimo de pontos (*MinPts*).
- Para cada dado, traçamos uma região de raio ϵ. Se dentro dessa região estiverem contidos *MinPts* ou mais, este ponto é considerado central (PC). Se estiverem contidos menos que o *MinPts* porém estiver próximo de outros PC's, é ponto de borda (PB). E se dentro de ϵ estiverem contidos menos de *MinPts* e nenhum dos pontos próximos forem PC's, é considerado *outlier*.
- A partir dessa classificação, são identificados os agrupamentos.

Este método, como o nome nos informa, foi desenvolvido para lidar também com bases de dados com ruído, além de que consegue detectar agrupamentos com formatos não lineares e não precisa que informemos o número de grupos. Porém, um ponto de atenção é a escolha dos parâmetros ϵ (raio da vizinhança) e do número mínimo de pontos, que é arbitrária.

3.4 *Fuzzy C-means*

De acordo com Ghosh e Dubey (2013), o *Fuzzy C-means* é um método de *soft clustering* amplamente utilizado em problemas de agricultura, astronomia, química, geologia, análise de imagem, entre outros. O algoritmo é baseado na distância entre os pontos de entrada. Os agrupamentos são formados de acordo com o cálculo da distância entre os pontos de dados e o centro do grupo. Foi proposto por Dunn (1973). Enquanto o *k-means* minimiza a inércia $\sum_{i=1}^{k} \sum_{x \in C_i} ||x - \mu_i||^2$, o *fuzzy c-means* minimiza o custo ponderado $\sum_{i=1}^{c} \sum_{j=1}^{n} u_{ij}^m ||x_j - v_i||^2$, em que u_{ij} é o grau de pertencimento do ponto x_j ao grupo i, v_i é o centroide do grupo i e m é o parâmetro de difusão.

1. Escolhemos um número c de grupos e inicializa aleatoriamente os centroides.
2. Para cada ponto, calcula o grau de pertencimento dele com o agrupamento designado, dado por $u_{ij} = \frac{1}{\sum_{k=1}^{c} \left(\frac{d_{ij}}{d_{ik}}\right)^{2/(m-1)}}$, em que d_{ij} é a distância do ponto i e o centro do grupo j, c é o número de grupos e m é o parâmetro de *"fuzzificação"*, que controla o quão suave é o pertencimento.
3. Atualiza todos os centros dos grupos.
4. Repete as etapas 2 e 3 até que os centros parem de mudar.

Quando comparado com o *k-means*, este método é mais sensível a outliers por conta dos pesos, que acabam suavizando a influência deles; porém, é mais lento por ter que realizar mais cálculos.

3.5 *Self-organizing maps*

O *self-organizing maps* é uma técnica de *hard clustering* baseada na teoria das redes neurais, proposta em Kohonen (1990). É utilizada para redução de dimensionalidade, agrupamento e visualização de dados e, além disso, consegue identificar padrões em dados complexos (VESANTO; ALHONIEMI, 2000). Este método funciona da forma iterativa descrita a seguir:

1. Define m pontos aleatórios no espaço dos dados, chamados de neurônios.
2. Para cada ponto, calcula a distância para todos os neurônios, definidos a priori. O neurônio com menor distância é classificado como *best-matching unit* (BMU).
3. O BMU e os neurônios vizinhos i são movidos na direção do ponto, recebendo novos pesos por meio do seguinte cálculo:

$$w_i(t+1) = w_i(t) + \alpha(t) h_{bi}(t)[x_i - w_i(t)],$$

em que $w_i(t)$ é o peso do neurônio no tempo t, $\alpha(t)$ a taxa de aprendizado, x_i é o dado e $h_{bi}(t)$ a função de vizinhança, geralmente dada por $h(x_i, x_j) = e^{\left(-\frac{d(x_i,x_j)^2}{2\sigma^2}\right)}$.

4. Repete os processos acima descritos até que o mapa se estabilize, e alterações significativas nos pesos dos neurônios parem de ocorrer.

Após esse processo iterativo, pontos que estão próximos aos neurônios são agrupados, formando os *clusters*.

3.6 Métricas de avaliação

Diversas métricas de validação para métodos de agrupamento têm sido utilizadas, a fim de verificar sua eficácia. Elas são divididas em dois grupos: métricas de validação externa e de validação interna.

Neste trabalho, aplicaremos o índice de Dunn para metrificar a variação *intra-cluster* e *inter-cluster* dos agrupamentos, a silhueta para entender o quanto cada ponto está bem agrupado e o índice de Rand corrigido para comparar os *clusters* com as partições de rótulos originais.

3.6.1 Validação interna

De acordo com Palacio-Niño e Berzal (2019), métodos de validação interna são capazes de mensurar a qualidade do agrupamento sem informações sobre a estrutura real dos dados, ou seja, sem rótulos originais. Este tipo de validação possui métricas de separação e de coesão. As de separação quantificam o grau de separação dentro do grupo, e as de coesão o quão próximas estão as observações umas das outras.

3.6.1.1 Índice de Dunn

O índice de Dunn, proposto por Dunn (1974), é a razão da menor distância entre dois pontos de dados de diferentes agrupamentos e a maior distância entre grupos. Ele leva em consideração tanto a coesão quanto a separação por considerar tanto a dispersão inter-cluster quanto a intra-cluster. Seu cálculo é dado por:

$$D = \min_{k_1=1,\dots,K} \left(\min_{k_2=1,\dots,K, k_1 \neq k_2} \left(\frac{\delta(C_{k_1}, C_{k_2})}{\max_{k_3=1,\dots,K}\{\Delta(C_{k_3})\}} \right) \right),$$

sendo $\Delta(C_{k_3}) = \max_{x_i, x_m \in C_{k_3}}\{d(x_i, x_m)\}$ e $\delta(C_{k_1}, C_{k_2}) = \min_{x_i \in C_{k_1}, x_m \in C_{k_2}}\{d(x_i, x_j)\}$. Ou seja, tendo dois grupos, podemos interpretar que $\delta(C_{k_1}, C_{k_2})$ é a menor distância entre dois pontos destes dois diferentes agrupamentos, ao passo que $\Delta(C_{k_3})$ representa a maior distância entre dois pontos pertencentes a um mesmo agrupamento.

3.6.1.2 Silhueta

A silhueta é um método de validação muito utilizado porque combina tanto a coesão quanto a separação em uma única medida. Proposto por Rousseeuw (1987), ela mede a similaridade de um ponto com seu próprio agrupamento, comparando-o com os outros. É uma forma de metrificar o quanto um ponto específico está bem alocado no agrupamento designado. Para calcular, precisamos seguir os passos descritos a seguir:

1. Calcula-se a distância média de cada ponto no grupo a ele designado:

$$a(x_i) = \frac{1}{|C_a|} \sum_{x_j \in C_a, i \neq j}^{n} d(x_i, x_j)$$

2. Depois, calcula-se a distância média de cada ponto para com todos os pontos do agrupamento mais próximo:

$$b(x_i) = min_{C_b \neq C_a} \frac{1}{C_b} \sum_{j \in C_b}^{n} d(x_i, x_j)$$

3. Finalmente, obtemos o coeficiente da silhueta para cada ponto de dados:

$$s(x_i) = \frac{b(x_i) - a(x_i)}{\max\{a(x_i), b(x_i)\}}$$

Após obter o valor da silhueta para cada ponto, podemos também calcular um coeficiente geral, dado por $S = \frac{1}{n} \sum_{i=1}^{n} s(x_i)$, que é uma média geral das silhuetas individuais. Os valores são definidos entre -1 e 1, sendo:

- $s(i) \approx 1$: ponto bem agrupado;
- $s(i) \approx 0$: ponto está entre grupos;
- $s(i) \approx -1$: ponto está no grupo errado.

3.6.2 Validação externa

Segundo Palacio-Niño e Berzal (2019), os métodos de validação externa são associados principalmente a problemas de aprendizado supervisionado, ou seja, quando temos os rótulos originais (grupos definidos *a priori*). Para que possamos utilizar estas métricas, devemos ou criar rótulos seguindo regras de negócio como o princípio de Pareto, matriz RFM ou até o resultado de uma técnica de agrupamento anteriormente utilizada.

3.6.2.1 Índice de Rand corrigido

Proposto por Hubert e Arabie (1985) o índice de Rand corrigido é equivalente à acurácia em problemas de aprendizado supervisionado. Ou seja, ele mede o quanto nosso método tem acertado, dados os rótulos originais. Definimos duas partições de n pontos de dados por $U = \{u_1, u_2, \ldots, u_c\}$ e $V = \{v_1, v_2, \ldots, v_k\}$, sendo U conhecida a priori e V o resultado do algoritmo de agrupamento. Podemos construir uma tabela de contingência entre essas duas partições que servirá para o cálculo do índice. Seja n_{ij} o número de pontos classificados no grupo u_i e no grupo v_j, o índice de Rand corrigido fica dado da seguinte forma:

$$ARI = \frac{\sum_{i=1}^{c}\sum_{j=1}^{k}\binom{n_{ij}}{2} - \binom{n}{2}^{-1}\sum_{i=1}^{c}\binom{n_i}{2}\sum_{j=1}^{k}\binom{n_j}{2}}{\frac{1}{2}\left[\sum_{i=1}^{c}\binom{n_i}{2} + \sum_{j=1}^{k}\binom{n_j}{2}\right] - \binom{n}{2}^{-1}\sum_{i=1}^{c}\binom{n_i}{2}\sum_{j=1}^{k}\binom{n_j}{2}},$$

em que $\binom{y}{x} = \frac{y!}{x!(y-x)!}$. O cálculo deste índice nos retorna um valor no intervalo [-1, 1], no qual 1 representa 100% de acerto entre as duas partições analisadas, 0 representa concordâncias ao acaso e -1 representa 0% de acerto.

4 Resultados e Discussão

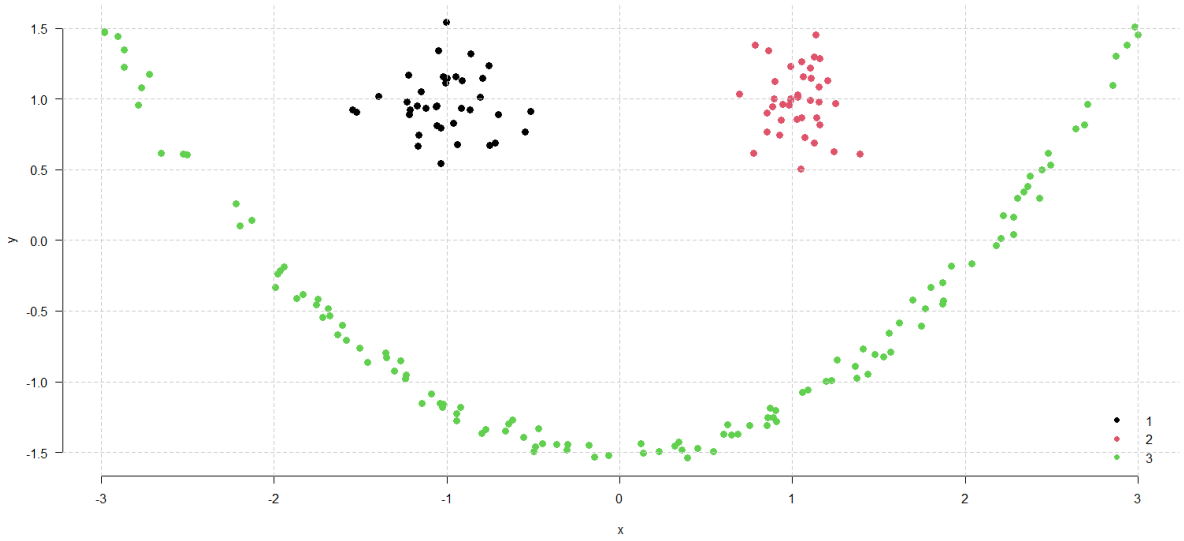
4.1 Aplicação em dados artificiais

Nesta seção, iremos aplicar o agrupamento por vetores de suporte em diversas bases provenientes de simulação, e comparar os resultados com os métodos acima descritos. Vale ressaltar que todos os dados foram previamente normalizados para que as comparações sejam justas.

4.1.1 *Smile*

Como pode ser visto na Figura 1, o comportamento dos dados é não linear, o que pode dificultar bastante o agrupamento por métodos que têm como base o cálculo de distâncias euclidianas (*k-means, fuzzy c-means* e agrupamento hierárquico).

Figura 1 – *Smile* com rótulos originais

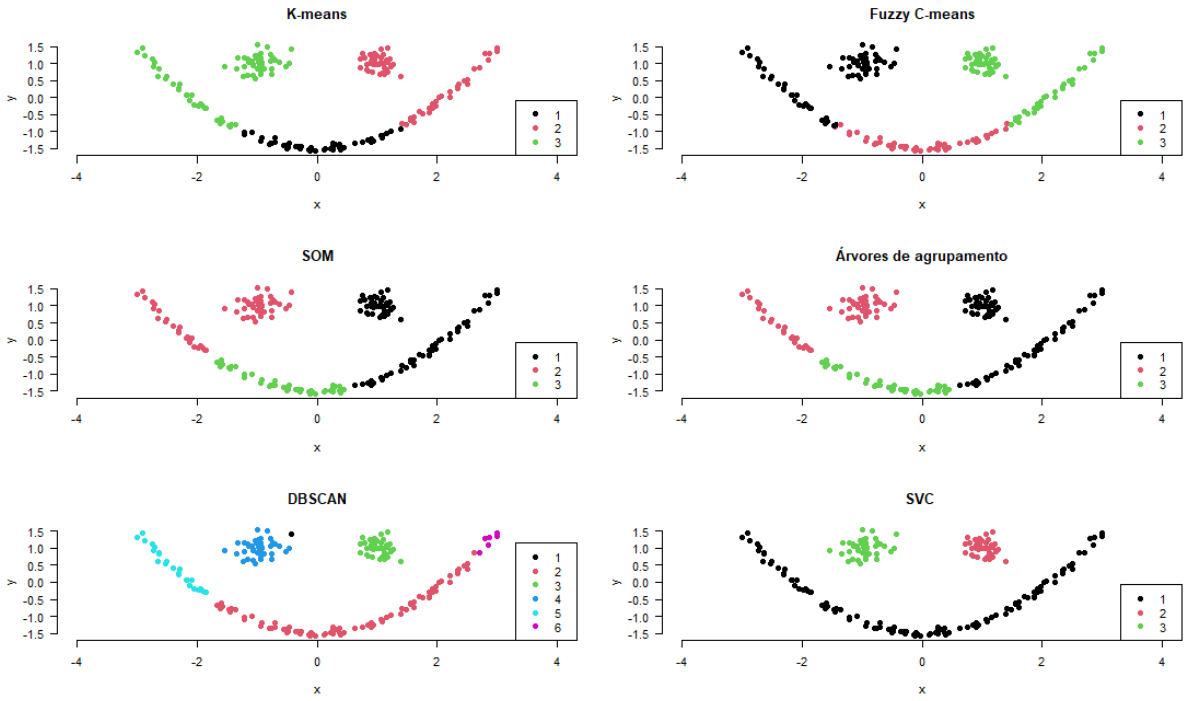


Fonte: O autor.

Após realizarmos os agrupamentos, podemos ver na Figura 2 que o único método que agrupa os dados corretamente, baseado nos rótulos originais, é o agrupamento por vetores de suporte. Apesar de informarmos para o *kmeans, fuzzy c-means, SOM* e agrupamento hierárquico o número de grupos, eles não foram capazes de identificar os conjuntos corretamente. É interessante notar que o DBSCAN encontra corretamente os dois agrupamentos centrais, que representam os "olhos"do sorriso, porém erra ao identificar

a "boca", transformando-a em três agrupamentos distintos e encontrando um *outlier*, representado pelo grupo 1.

Figura 2 – Agrupamentos da base *Smile*



Fonte: O autor.

Depois do cálculo das métricas (Tabela 1), observamos que, de acordo com o índice de Rand corrigido, o SVC se mostra como a técnica mais adequada, seguido pelo DBSCAN. Como visto anteriormente, foram os dois métodos que mais conseguiram captar o formato não linear dos dados, ao passo que os outros quatro erraram bastante, com valores abaixo de $0,5$. É interessante notar que, pelo índice de Dunn, o SVC também é a mais adequada. De acordo com essa métrica, o DBSCAN possui um valor bem baixo, acima somente do *SOM* e *k-means*. A silhueta considera o agrupamento por vetores de suporte como o menos adequado, e o *fuzzy c-means* como o de melhor desempenho.

Tabela 1 – Métricas para *Smile*

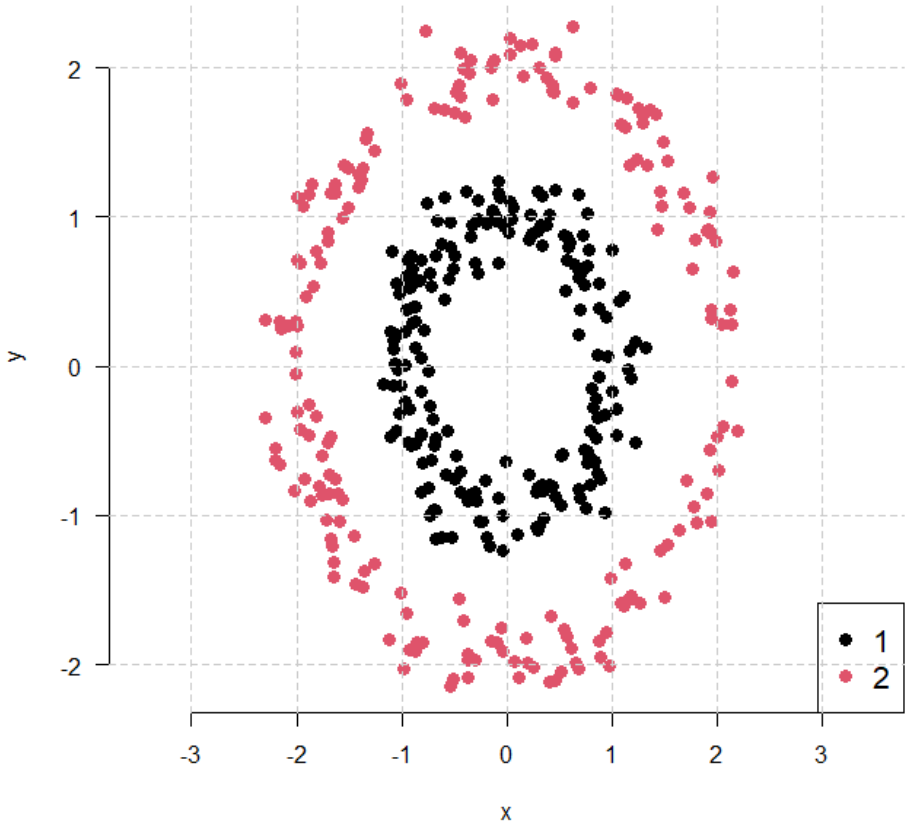
Método	ARI	Índice de Dunn	Silhueta
K-means	0,426	0,024	0,411
Fuzzy C-means	0,229	0,047	0,527
SOM	0,202	0,021	0,500
Agrupamento hierárquico	0,167	0,055	0,495
DBSCAN	0,847	0,027	0,296
SVC	1,000	0,154	0,224

Fonte: O autor.

4.1.2 *Two rings*

Como pode ser visto na Figura 3, assim como na base de dados *Smile*, os dados possuem formas não lineares.

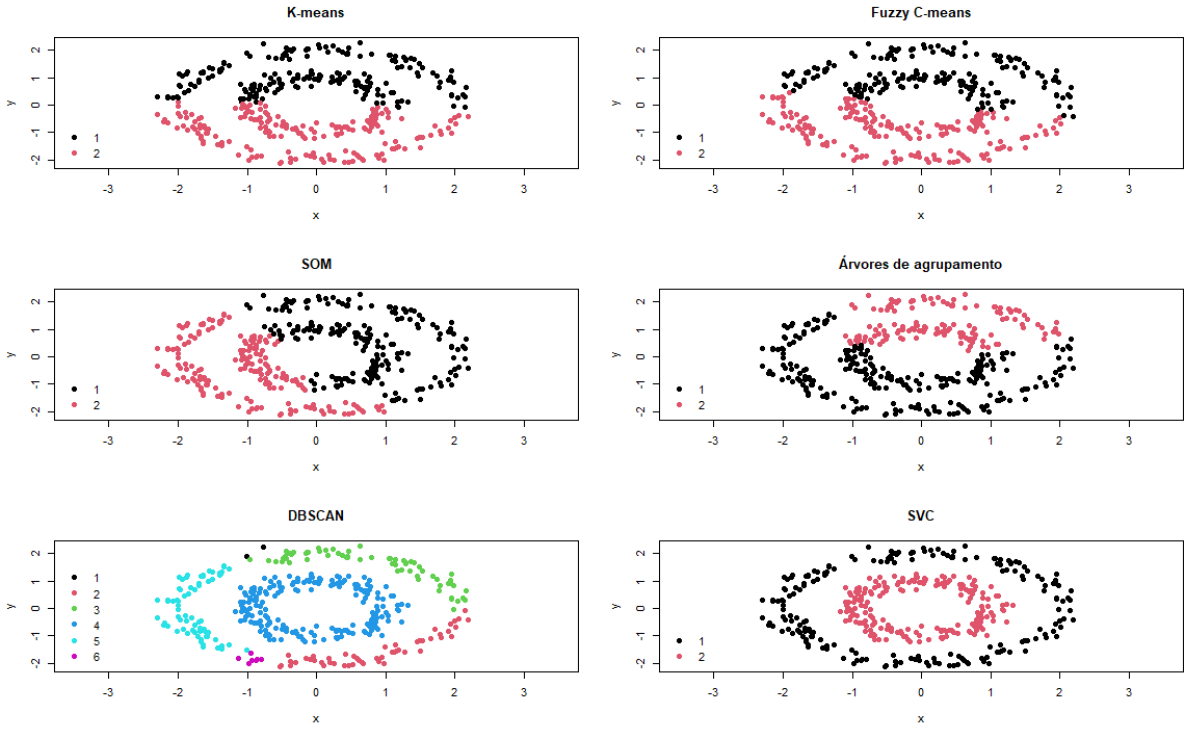
Figura 3 – *Two rings* com rótulos originais



Fonte: O autor.

Após aplicarmos os agrupamentos, validamos novamente que o agrupamento por vetores de suporte superou os outros, visto que agrupa identicamente os dados, quando comparado com os rótulos originais. Também, como podemos ver na Figura 4, os únicos dois métodos que agruparam corretamente o anel interior foram o DBSCAN e o SVC, porém, o primeiro não conseguiu identificar o anel exterior, observando quatro *clusters* e dois pontos *outliers* (em preto). Por meio da análise gráfica, podemos concluir que os outros quatro métodos, mesmo informando o número de grupos, não conseguiram identificá-los com êxito.

Figura 4 – Agrupamentos da base *Two Rings*



Fonte: O autor.

Após a obtenção das métricas (Tabela 2) conseguimos concluir que os métodos SVC e DBSCAN se mostram mais adequados considerando as métricas ARI e índice de Dunn. Já pela silhueta, o método considerado mais adequado foi o *fuzzy c-means*, seguido pelo *k-means*. Por essa métrica, tanto o DBSCAN quanto o agrupamento por vetores de suporte tiveram as piores performances.

Tabela 2 – Métricas para *Two Rings*

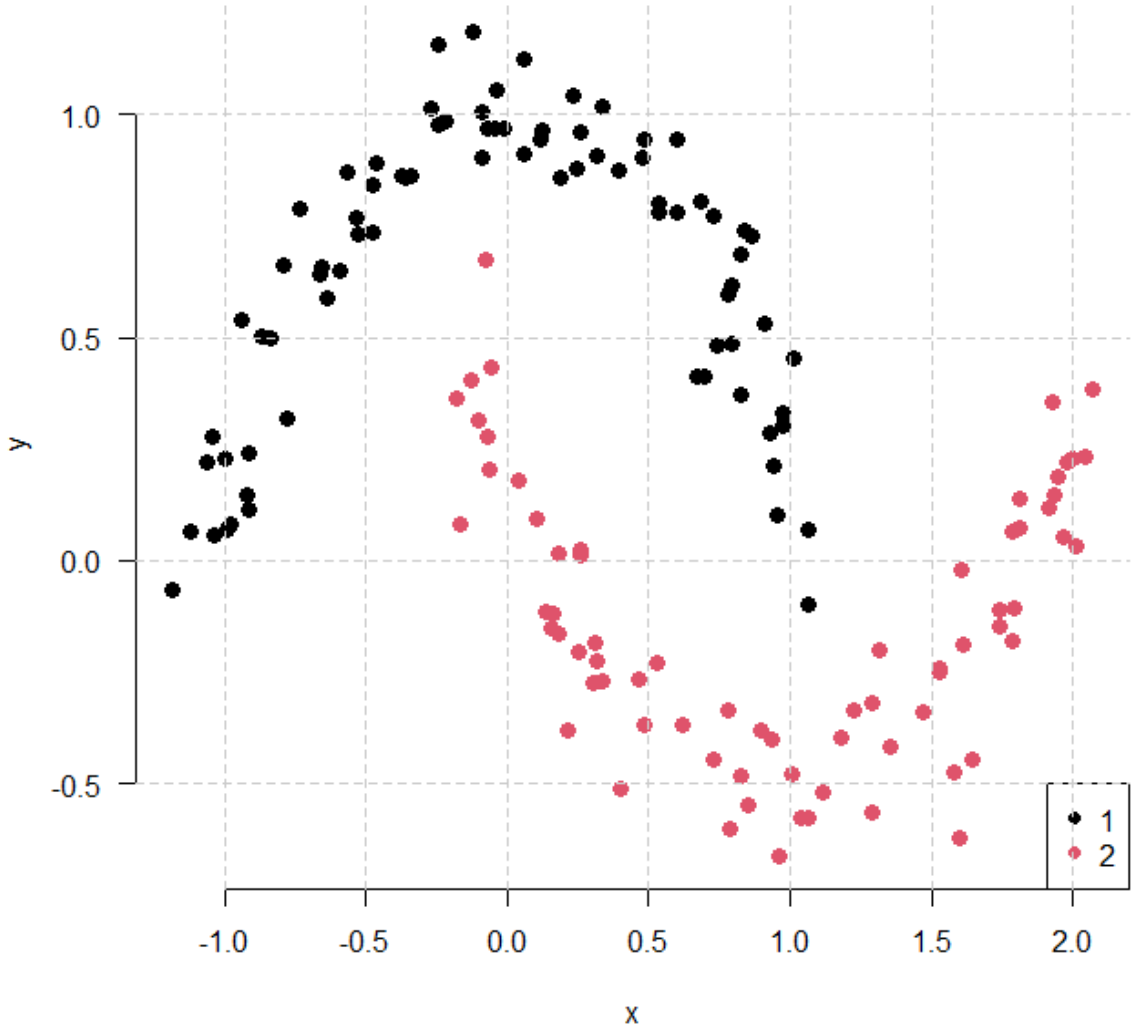
Método	ARI	Índice de Dunn	Silhueta
K-means	-0,001	0,019	0,357
Fuzzy C-means	-0,002	0,014	0,369
SOM	0,018	0,025	0,299
Agrupamento hierárquico	0,009	0,027	0,314
DBSCAN	0,655	0,041	0,066
SVC	1,000	0,086	0,110

Fonte: O autor.

4.1.3 *Two Moons*

Como pode ser visto na Figura 5, novamente os dados se comportam de forma não linear, o que dificulta o agrupamento por métodos que utilizam distâncias euclidianas em seus cálculos.

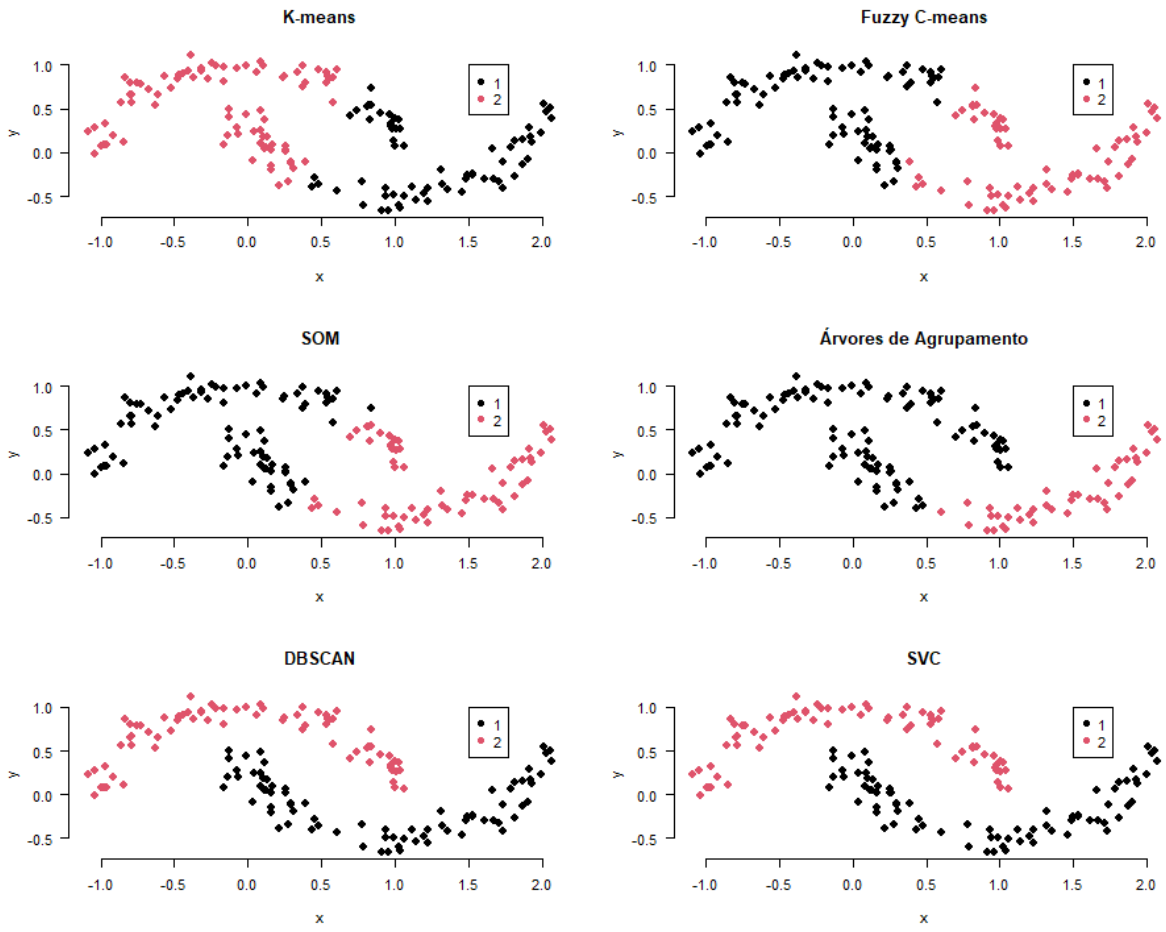
Figura 5 – *Two Moons* com rótulos originais



Fonte: O autor.

De acordo com a análise gráfica da Figura 6, identificamos que, assim como nas outras duas aplicações, o agrupamento por vetores de suporte foi a técnica mais parecida com os rótulos originais, juntamente ao DBSCAN. Todos os outros quatro métodos identificam os *clusters* de uma forma semelhante.

Figura 6 – Agrupamentos da base *Two Moons*



Fonte: O autor.

Ao observar as métricas calculadas, identificamos o SVC e o DBSCAN como sendo as técnicas mais adequadas, de acordo com o ARI e o índice de Dunn, o que corrobora com a análise gráfica anteriormente feita. Novamente, pela silhueta, os dois métodos com maior performance foram o *k-means* e *fuzzy c-means*, com o agrupamento por vetores de suporte e DBSCAN com menores valores.

Tabela 3 – Métricas para *Two moons*

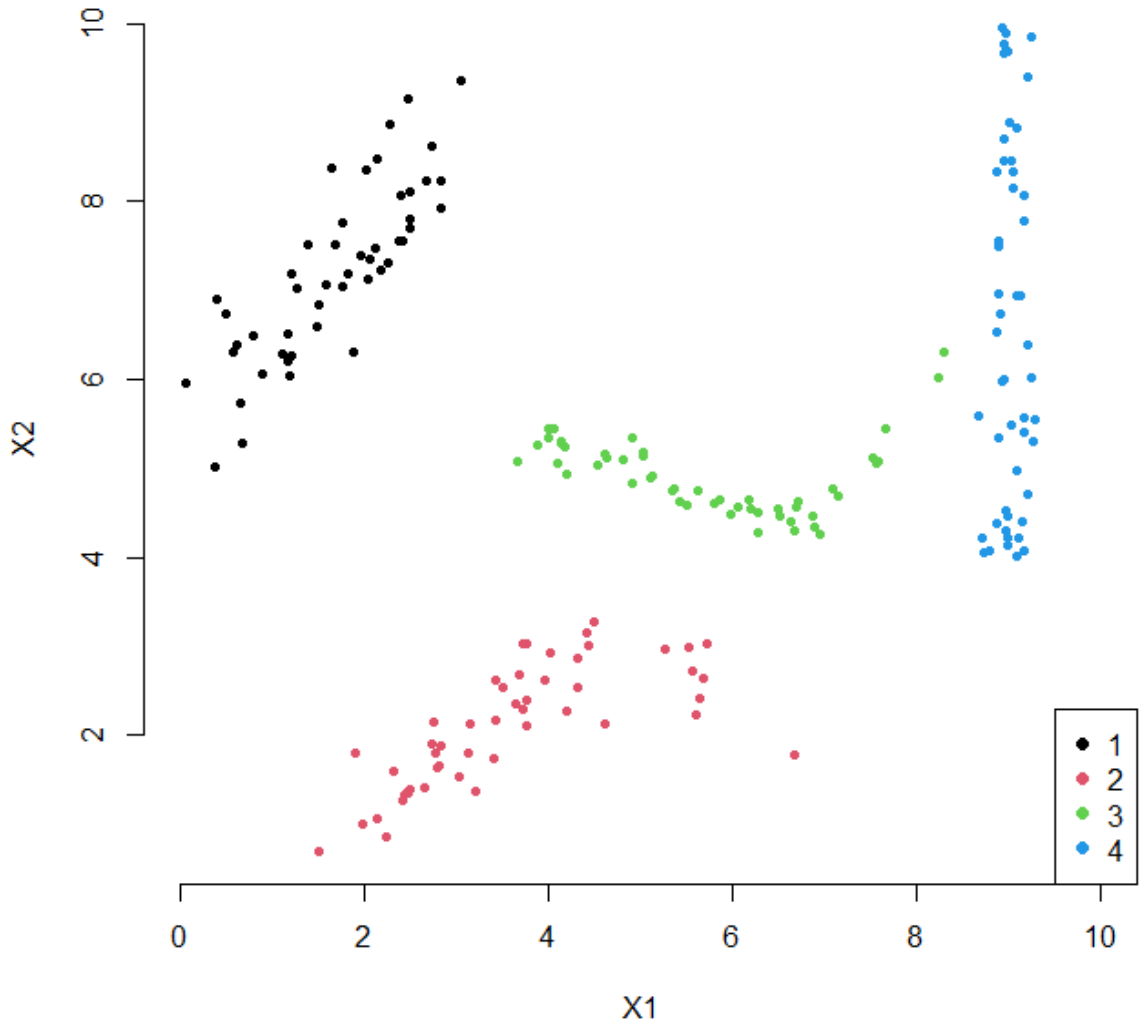
Método	ARI	Índice de Dunn	Silhueta
K-means	0,114	0,089	0,487
Fuzzy C-means	0,123	0,049	0,485
SOM	0,574	0,084	0,486
Agrupamento hierárquico	0,309	0,069	0,460
DBSCAN	1,000	0,135	0,285
SVC	1,000	0,135	0,285

Fonte: O autor.

4.1.4 *Noisy data*

Nesta aplicação, observamos uma base de dados com formas não lineares, o que pode dificultar a identificação dos padrões vistos nos rótulos originais na aplicação de métodos baseados em distâncias euclidianas (Figura 7).

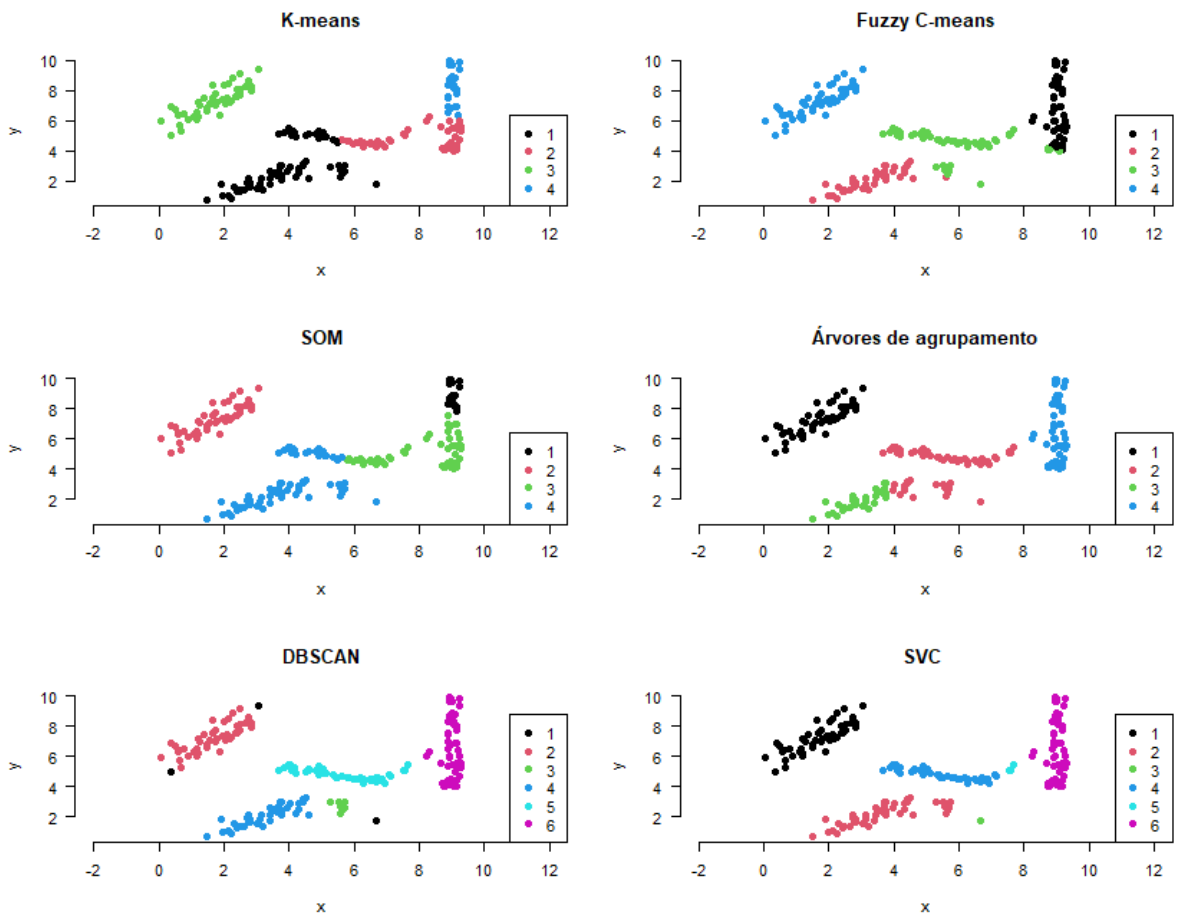
Figura 7 – *Noisy data* com rótulos originais



Fonte: O autor.

De acordo com a Figura 8, pode-se observar que os agrupamentos baseados no cálculo da distância euclidiana identificam padrões não vistos nos rótulos originais. O SVC, por sua vez, agrupa de maneira parecida com a Figura 7, visto que observou corretamente três dos quatro grupos originais.

Figura 8 – Agrupamentos da base *noisy data*



Fonte: O autor.

Pela análise das métricas (Tabela 4), percebe-se que o SVC se mostra mais adequado considerando o ARI, *clusterizando* quase que de forma idêntica aos rótulos originais, seguido pelo DBSCAN. A silhueta premiou o *fuzzy c-means*, o *k-means* e o agrupamento hierárquico, por conta do cálculo da distância euclidiana.

Tabela 4 – Métricas para *noisy data*

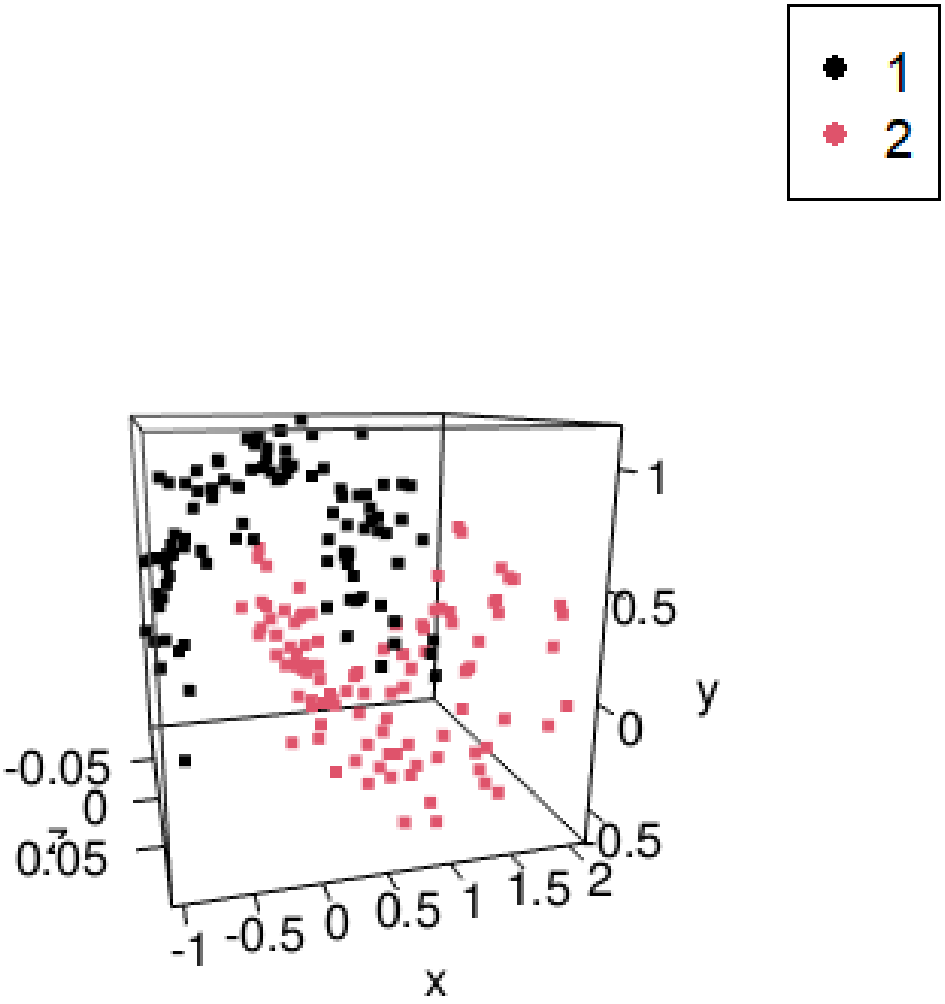
Método	ARI	Índice de Dunn	Silhueta
K-means	0,589	0,035	0,522
Fuzzy C-means	0,818	0,017	0,534
SOM	0,576	0,037	0,521
Agrupamento hierárquico	0,786	0,046	0,531
DBSCAN	0,909	0,136	0,473
SVC	0,940	0,093	0,357

Fonte: O autor.

4.1.5 *Two moons* em três dimensões

Na última aplicação em dados simulados, temos a base de dados *two moons* com três dimensões (Figura 9). A grande diferença desse conjunto para o *two moons* 2D, trabalhado anteriormente, é a presença de uma dimensão z o que insere mais um elemento para o cálculo dos métodos.

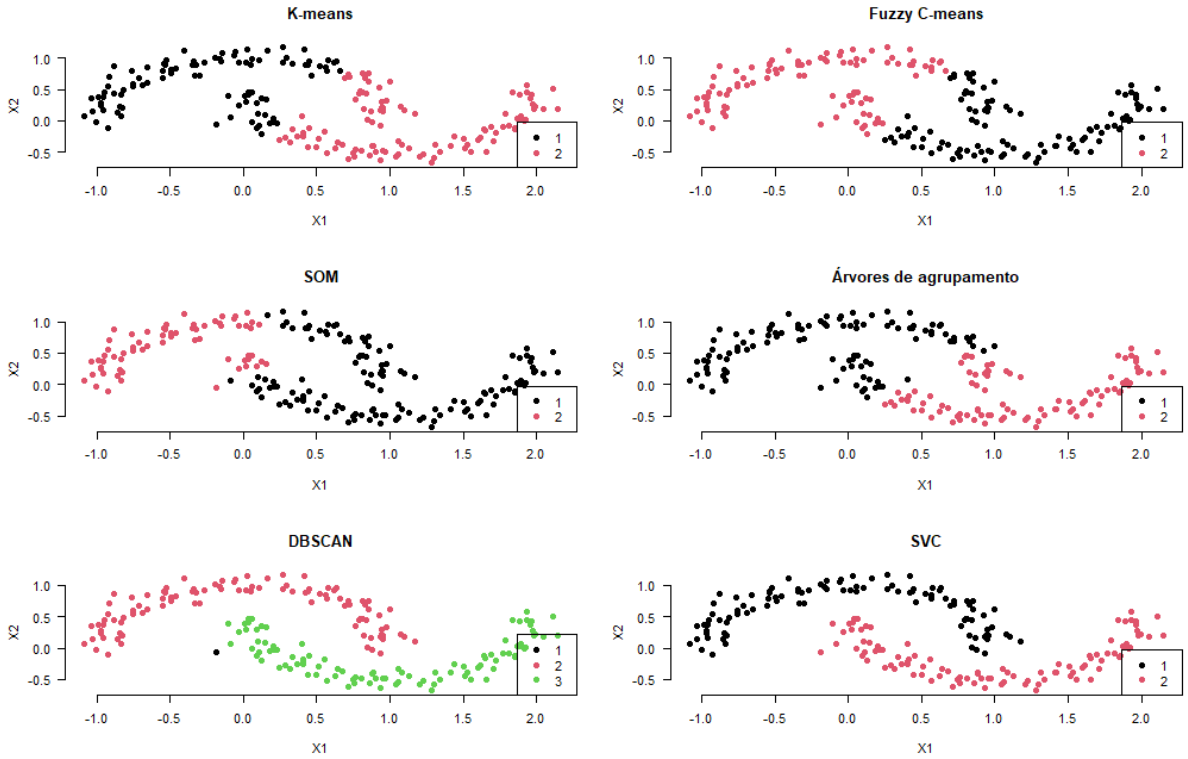
Figura 9 – *Two moons* 3D



Fonte: O autor.

Focando apenas em dois eixos do gráfico (Figura 10) pode-se reparar que o SVC e DBSCAN obtiveram resultados parecidos, com o segundo método identificando um *outlier*, em preto. Os outros quatro métodos agrupam de maneira parecida.

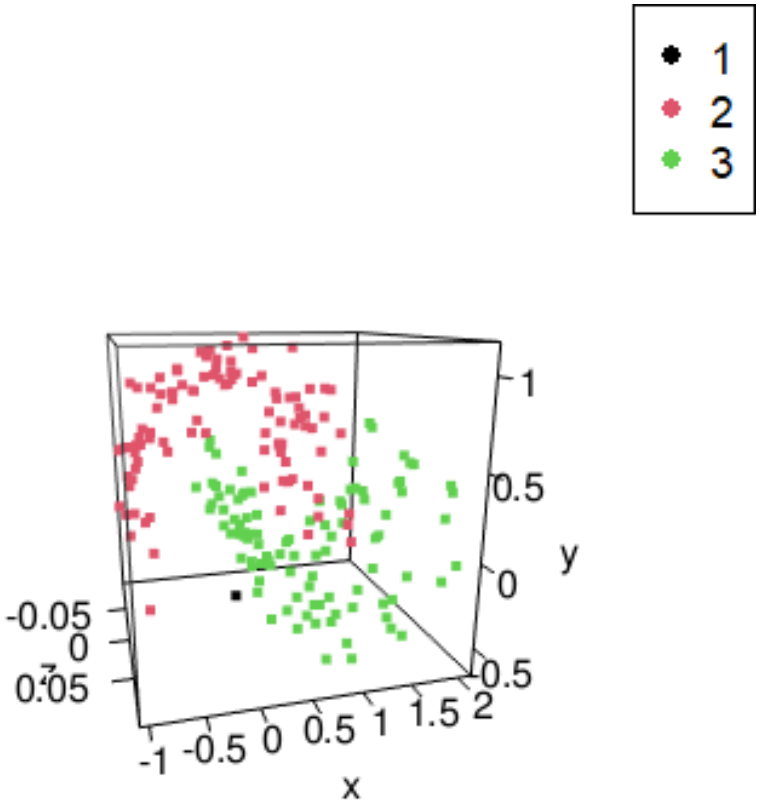
Figura 10 – Agrupamentos para *Two moons* 3D



Fonte: O autor.

Na Figura 11 entendemos melhor como o agrupamento final foi definido, para o DBSCAN.

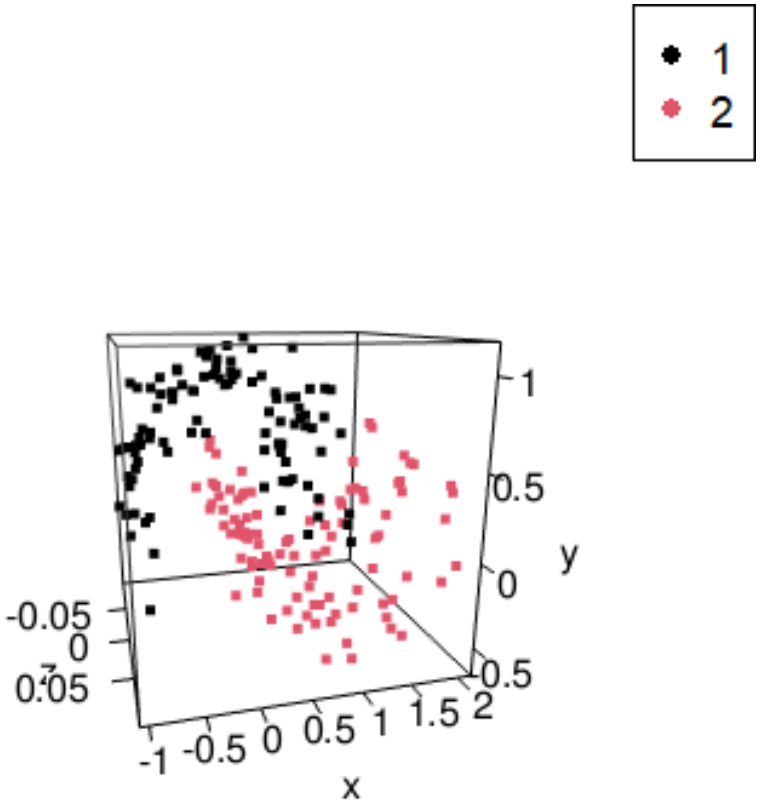
Figura 11 – DBSCAN para *Two moons* 3D



Fonte: O autor.

Já na Figura 12 podemos observar como o agrupamento foi feito para o SVC. Novamente, se compararmos com a Figura 9, que representa os rótulos originais, pode-se identificar que o SVC foi impecável.

Figura 12 – SVC para *Two moons* 3D



Fonte: O autor.

De acordo com as métricas calculadas (Tabela 5) observamos que o SVC superou os outros métodos pelo índice de Rand corrigido, e ficou atrás só do DBSCAN pelo índice de Dunn.

Tabela 5 – Métricas para *two moons* 3D

Método	ARI	Índice de Dunn	Silhueta
K-means	0,246	0,047	0,475
Fuzzy C-means	0,246	0,047	0,475
SOM	0,190	0,073	0,440
Agrupamento hierárquico	0,333	0,069	0,466
DBSCAN	0,990	0,117	0,057
SVC	1,000	0,112	0,311

Fonte: O autor.

4.2 Aplicação em dados reais

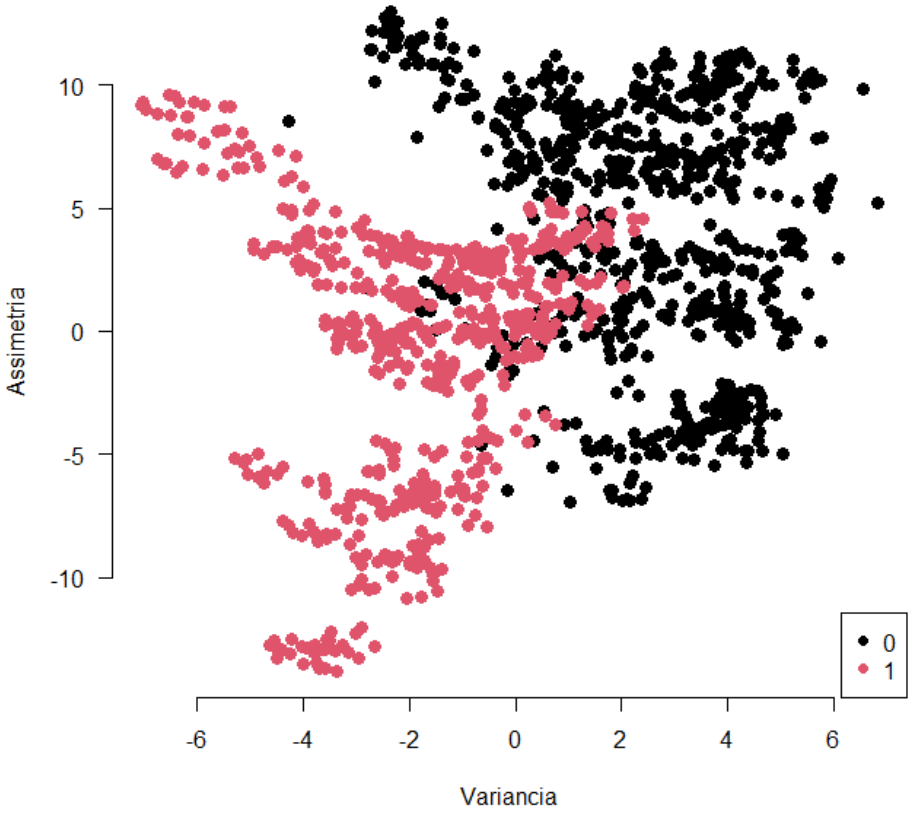
Após as aplicações em bases simuladas, prosseguimos para as aplicações em bases de dados reais. Nesta seção também vale ressaltar que todos os dados foram previamente normalizados para que as comparações sejam justas.

4.2.1 *Banknote Authentication*

A base de dados *banknote authentication* (archive.ics.uci.edu/dataset/267) possui informações sobre cédulas de dinheiro reais e falsas. São 1372 linhas e 5 colunas, que representam a variância, assimetria, curtose e entropia das imagens dessas cédulas transformadas via Wavelet, além da coluna de classe, representando notas falsas como 0 e notas originais como 1.

Como podemos ver na Figura 13, os dados não são linearmente divisíveis, e possui uma área com dados das duas classes mesclados.

Figura 13 – Base *banknotes*

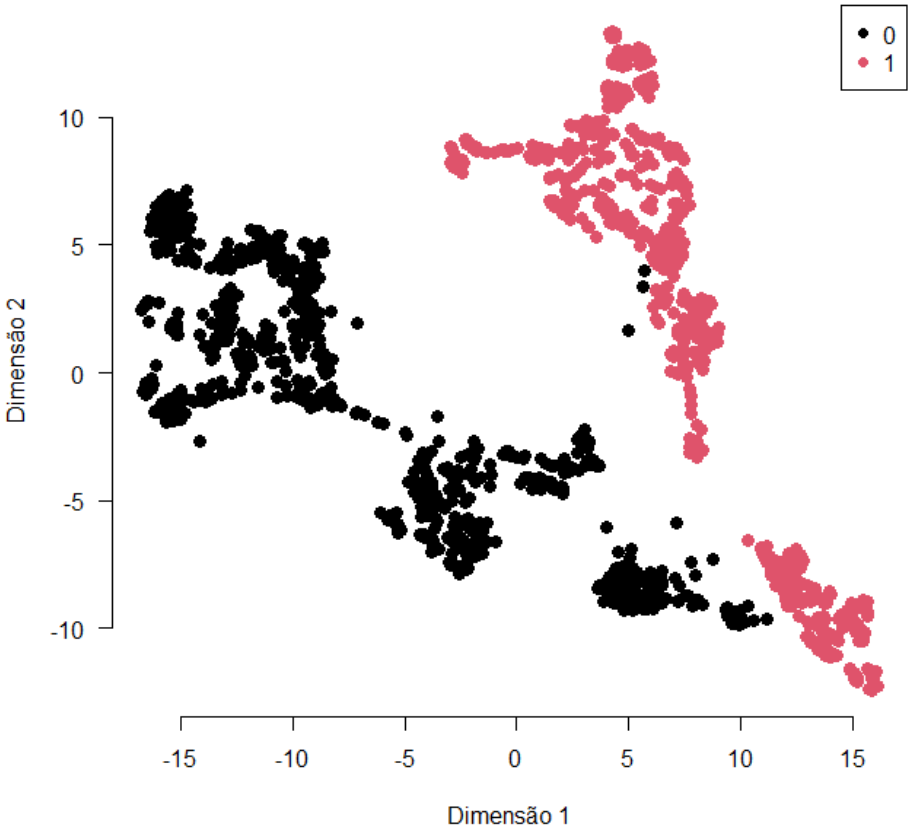


Fonte: O autor.

Para sanar essa questão dos dados de duas classes mesclados, aplicamos a técnica

de redução de dimensionalidade t-SNE (MAATEN; HINTON, 2008), que visa manter as vizinhanças entre os dados, e que é de grande valia para esse agrupamento. Após a aplicação da redução podemos ver como as duas dimensões foram definidas, como visto na Figura 14.

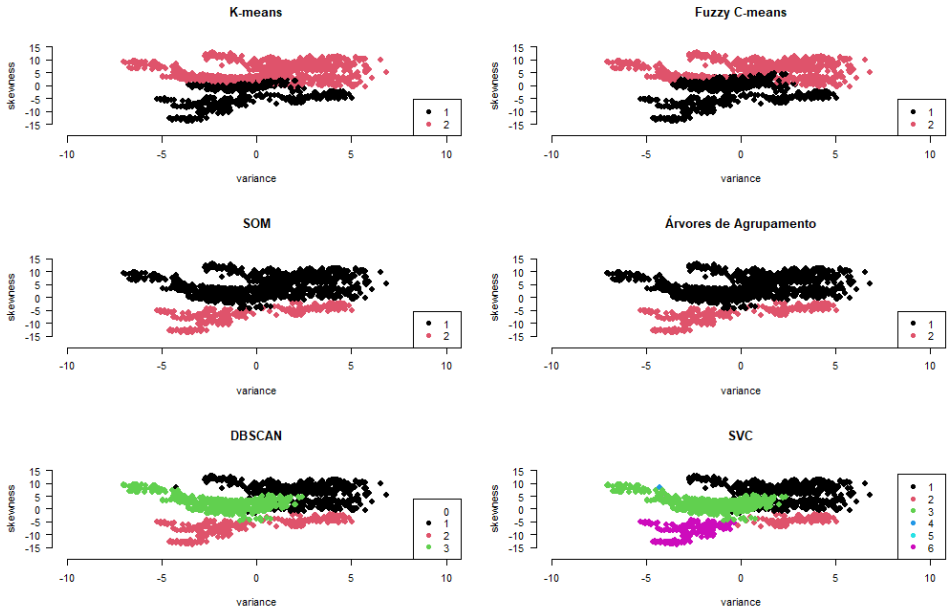
Figura 14 – t-SNE aplicado a *banknotes authentication*



Fonte: O autor.

Nessas dimensões provenientes da redução, aplicamos os agrupamentos e verificamos como eles se comportaram na base de dados original (Figura 15). Podemos perceber que o agrupamento por vetores de suporte identificou 4 grupos, e o DBSCAN 3.

Figura 15 – Agrupamentos em *banknotes authentication*



Fonte: O autor.

E finalmente, de acordo com as métricas na Tabela 6, identificamos que, pelo índice de Rand corrigido, o SVC se mostrou o método mais adequado, seguido pelo DBSCAN, ao passo que, de acordo com a silhueta, o agrupamento por vetores de suporte é o de menor desempenho.

Tabela 6 – Métricas para *banknotes authentication*

Método	ARI	Índice de Dunn	Silhueta
K-means	0,284	0,013	0,462
Fuzzy C-means	0,267	0,001	0,454
SOM	0,017	0,040	0,381
Agrupamento hierárquico	0,233	0,024	0,473
DBSCAN	0,603	0,105	0,316
SVC	0,652	0,048	0,053

Fonte: O autor.

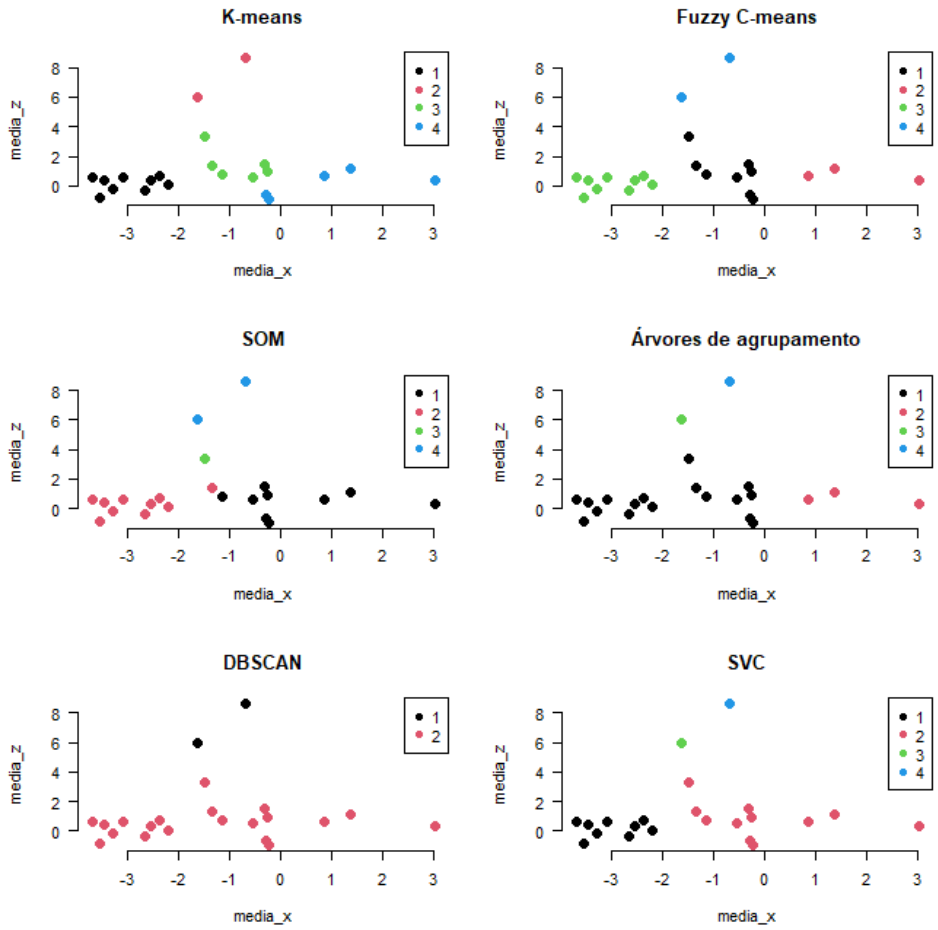
4.2.2 *User identification from walking activity*

O *dataset user identification from walking activity* (archive.ics.uci.edu/dataset/286) representa dados coletados de *smartphones* alocados no bolso de 22 participantes. Foram armazenados o tempo, a aceleração em x, em y e em z. Ele é bastante interessante para analisar o comportamento durante a caminhada dos usuários. Para cada usuário, temos um arquivo em formato *comma-separated values* (CSV), com as informações acima descritas. Para tornar esses dados mais fáceis de serem utilizados, para cada usuário calculamos a

média de x, y e z, obtendo assim uma base de dados com 22 linhas, representando os usuários, e 3 colunas.

Em uma primeira visão, com duas dimensões (Figura 16), podemos observar quais padrões foram identificados pelas diferentes técnicas de agrupamento. O SVC observou quatro grupos, sendo 1 e 2 os maiores, e 3 e 4 pontos unitários. Para esses grupos unitários, podemos interpretar que foram identificados como pontos afastados da massa de dados principal, concentrada em valores baixos para z. O DBSCAN, após otimização dos parâmetros ϵ e $MinPts$, observou apenas dois agrupamentos, sendo um deles a massa de dados descrita anteriormente, e o outro os dois pontos afastados (*outliers*).

Figura 16 – Agrupamentos em *walking activity*

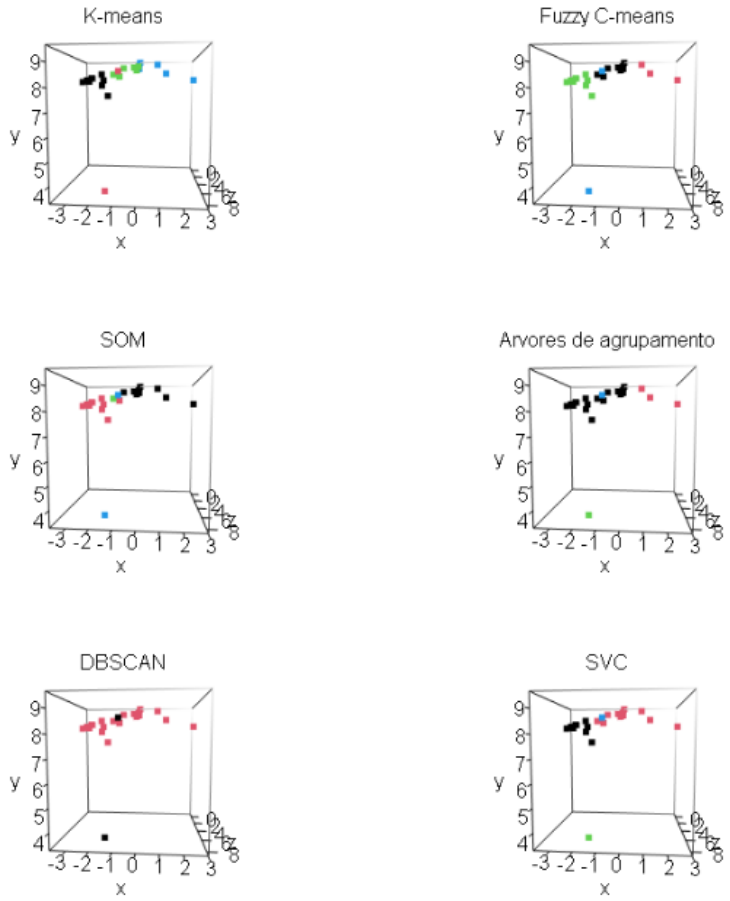


Fonte: O autor.

Já na Figura 17 pode-se ver como os dados se comportam em três dimensões. Nota-se que, se analisarmos apenas x e y, não observamos um ponto "mal agrupado", porém, quando voltamos para a Figura 16, temos a confirmação de que está corretamente *clusterizado*. Há um ponto bastante distante da grande massa de dados. Todos os métodos conseguiram incorporar essa distância nos grupos finais.

Está é uma análise interessante de ser feita, pois pode nos fornecer *insights* sobre como indivíduos se locomovem, e, agrupando indivíduos com padrões parecidos, conseguimos, por exemplo, colocar placas de publicidades voltadas para aquele público específico no caminho que percorrem. Obviamente, aqui incorporamos apenas a informação da caminhada, mas tendo mais dados sobre o perfil desses indivíduos, pode-se pensar em estratégias de *marketing* voltadas a estes grupos de pessoas, a fim de obter uma maior assertividade na conversão de produtos ou na disseminação de ideias.

Figura 17 – Agrupamentos em *walking activity* 3D



Fonte: O autor.

Partindo para a análise das métricas (Tabela 7), pode-se notar que o método mais adequado é o DBSCAN, seguido do SVC, de acordo com a silhueta. Apesar das métricas nos dizerem isso, observamos nos gráficos que o primeiro método identificou apenas 2 grupos, o que talvez não faria sentido, dada a natureza do problema. Provavelmente, para um problema de negócio, ter um resultado com apenas dois *clusters* para uma campanha de *marketing* não fosse de grande ajuda, ainda mais com um desses grupos sendo de apenas dois indivíduos. Vemos aqui que os métodos *k-means, fuzzy c-means* e *SOM* foram superados pelo DBSCAN e SVC, pela silhueta. Já no índice de Dunn, o DBSCAN é o de

melhor performance, seguido do agrupamento hierárquico e SVC.

Tabela 7 – Métricas para *walking activity*

Método	Índice de Dunn	Silhueta
K-means	0,192	0,402
Fuzzy C-means	0,192	0,423
SOM	0,132	0,399
Agrupamento hierárquico	0,250	0,362
DBSCAN	0,797	0,637
SVC	0,227	0,432

Fonte: O autor.

4.2.3 Capitais do Brasil

Nesta última aplicação, vamos trabalhar com o banco de dados contendo a latitude e longitude das capitais brasileiras (Figura 18), disponível em github.com/andersonara/.

Figura 18 – Capitais do Brasil

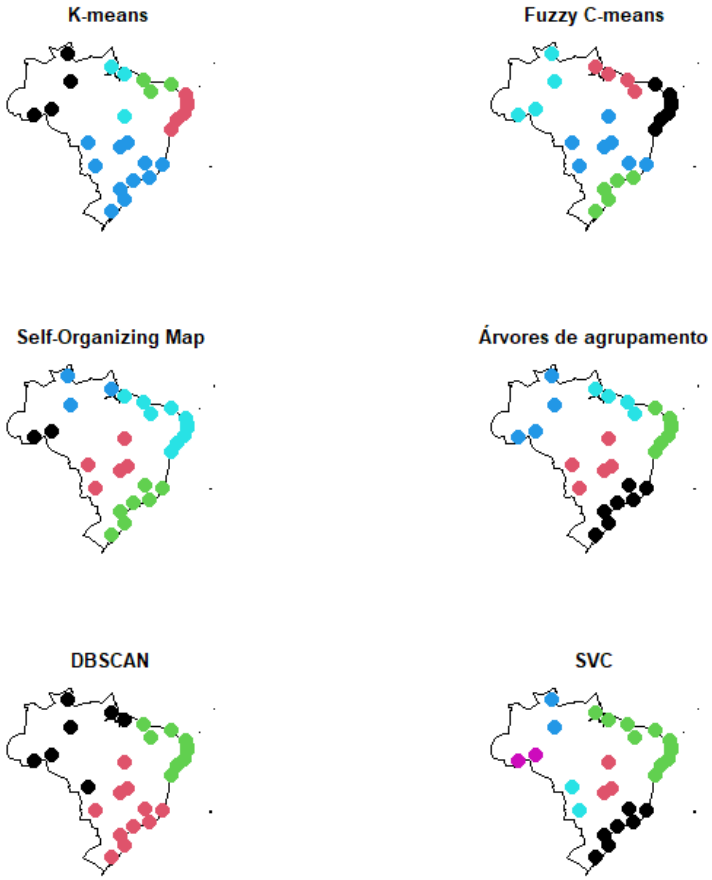


Fonte: O autor.

Vemos que os resultados foram bem variados (Figura 19), sendo que o *k-means* identificou um grande grupo das capitais na região sul, sudeste e centro-oeste. Além disso,

todos os métodos identificaram as capitais do litoral nordestino no mesmo agrupamento, com pequenas variações. Todos também agruparam as cidades do sul no mesmo grupo.

Figura 19 – Agrupamentos das capitais do Brasil



Fonte: O autor.

Partindo para a análise das métricas de validação (Tabela 8) conseguimos notar que, tanto pelo índice de Dunn quanto pela silhueta, o SVC superou os métodos *k-means*, *fuzzy c-means* e SOM, porém ficou atrás do agrupamento hierárquico e do DBSCAN. Nesse sentido, podemos observar que o DBSCAN identificou apenas três agrupamentos, o que acaba favorecendo essas métricas.

Tabela 8 – Métricas para capitais do Brasil

Método	Índice de Dunn	Silhueta
K-means	0,238	0,419
Fuzzy C-means	0,189	0,410
SOM	0,194	0,428
Agrupamento hierárquico	0,304	0,455
DBSCAN	0,375	0,465
SVC	0,316	0,433

Fonte: O autor.

Podemos perceber que, de acordo com as métricas utilizadas e a avaliação gráfica dos resultados, o agrupamento por vetores de suporte é o mais adequado, principalmente nas bases de dados simuladas. Precisamos ter um cuidado muito grande ao analisar tais métricas, pois, mesmo quando o SVC era claramente a melhor técnica, a silhueta apontava para outros métodos, geralmente *k-means* e *fuzzy c-means*. Portanto, para essas análises, a investigação de outras formas de validação foi de suma importância, visto que o ARI e o índice de Dunn escolhiam corretamente o SVC, quando ele era o método mais adequado. Além disso, podemos perceber como a análise gráfica também foi importante para chegarmos às conclusões, dado que nos permitiu obter mais uma opção de validação.

A silhueta, em específico, se utiliza diretamente da distância euclidiana em seus cálculos, o que acaba favorecendo métodos baseados nessa distância, como *k-means*, *fuzzy c-means* e agrupamento hierárquico. Como podemos ver no conjunto *smile* (Figura 1), os dois pontos mais dissimilares são as pontas do "sorriso", identificados em grupos diferentes pelo *k-means*, *fuzzy c-means*, SOM e agrupamento hierárquico; coincidentemente, os métodos de maior valor para a silhueta (Tabela 1). Portanto, talvez utilizar essa métrica para seleção de métodos não seja a melhor opção em bases de dados não linearmente separáveis. Já o índice de Dunn conseguiu captar melhor essa característica dos agrupamentos, penalizando bastante os outros métodos.

5 Considerações finais

O SVC demonstrou ser um método muito completo e com características interessantes, ao longo do trabalho. Ele não agrupa por meio de distâncias, mas sim por uma matriz de adjacência, validando segmentos de reta traçados em cada par de pontos. Esse método é capaz de incorporar o formato não linear dos dados nos grupos, algo que métodos mais conhecidos não fazem.

Vale ressaltar que para todas as aplicações, todos os métodos foram otimizados, ou seja, utilizamos as técnicas apropriadas para encontrar os valores ótimos dos hiperparâmetros que produzem os resultados de suas *clusterizações*.

Estudos de simulação foram realizados para testar a eficiência do método estudado, bem como aplicações em bases de dados reais. Em ambos, o SVC apresentou um resultado satisfatório, visto que a identificação dos grupos aconteceu conforme o esperado. Essas aplicações mostraram uma alta taxa de acerto quando os dados eram separáveis, linearmente ou não linearmente. No estudo em dados reais, o SVC se mostrou bastante competente, quando comparado a outros métodos mais tradicionais, como *k-means* e agrupamento hierárquico.

As métricas de avaliação devem ser escolhidas com muito cuidado, visto que podem enviesar a escolha de um método ótimo. Neste trabalho, utilizamos duas métricas que levam em consideração distâncias euclidianas e, consequentemente, penalizaram técnicas de agrupamento que não têm essa distância dentro de seu escopo (DBSCAN e SVC). Quando realizávamos a comparação do resultado do agrupamento com os rótulos originais via índice de Rand corrigido, esses dois métodos se mostraram os mais eficientes, com o agrupamento por vetores de suporte sendo ligeiramente melhor.

O agrupamento por vetores de suporte não possui implementação na linguagem R, que utilizamos nesse trabalho. Por conta disso, tivemos que trabalhar muito na implementação de uma função que realizasse todos os cálculos e análises que o método faz, e isso foi bem desafiador. A implementação da parte matemática correu bem, mas a criação da matriz de adjacência, que verifica se cada ponto está no mesmo grupo que outro, foi a parte que mais demandou esforços. O grande problema enfrentado nessa etapa foi de tempo, pois, conforme o número de dados cresce, o tempo de computação cresce muito. Para uma base de dados com 150 dados, por exemplo, ela retornava uma matriz com 22.500 validações. Em uma base com 500 dados, uma matriz com 250.000.

O SVC deve ser comparado com outros métodos, como o *kernel k-means* e agrupamento espectral, para que se chegue à conclusão de que o método estudado realmente é o que possui melhor desempenho. Ou seja, deve-se realizar um *benchmark* mais abrangente com outras técnicas e métricas de validação.

Além disso, uma questão que também foi enfrentada tem relação com a escolha

do σ ótimo do núcleo gaussiano utilizado. Com diferentes valores para este parâmetro, nós obtínhamos agrupamentos bem variados. Para sanar essa questão, implementamos um *Grid Search* dentro da função, que buscava o melhor valor para este σ de acordo com a avaliação de algumas métricas: silhueta, índice de Dunn e *total within-cluster sum of square* (WSS), o que nos retornou bons resultados.

Um fruto desse trabalho é a criação de um pacote no R, que possui essa função. Estamos criando a documentação e o artigo dela para publicar no CRAN, mas antes, precisamos trabalhar mais em cima da otimização do σ e da obtenção da matriz de adjacência, além de implementar o cálculo do parâmetro de penalização da hiperesfera C.

Como trabalho futuro, pretende-se realizar melhorias na função criada no R, bem como analisar outras métricas de validação, que captem melhor a conectividade intra-cluster, ao invés de utilizar a distância euclidiana, que pode enviesar as comparações entre métodos, favorecendo técnicas que utilizem-na em seus cálculos. Outro tema de pesquisa futura também será a redução da complexidade e do esforço computacional do método estudado.

Referências Bibliográficas

AHMED, M.; SERAJ, R.; ISLAM, S. M. S. The k-means algorithm: A comprehensive survey and performance evaluation. *Electronics*, MDPI, v. 9, n. 8, 2020.

BAGCI, F. B.; KARAL Ömer. Exploring efficient kernel functions for support vector clustering. *Mugla Journal of Science and Technology*, 2020.

BEN-HUR, A. et al. Support vector clustering. *Journal of machine learning research*, v. 2, n. Dec, p. 125–137, 2001.

BLOCKEEL, L. D. R. H.; RAMON, J. Top-down induction of clustering trees. *Machine Learning, Proceedings of the 15th International Conference*, 2000.

CHIANG, J.-H.; HAO, P.-Y. A new kernel-based fuzzy clustering approach: support vector clustering with cell growing. *IEEE Transactions on Fuzzy Systems*, IEEE, v. 11, n. 4, p. 518–527, 2003.

CHRISTODOULAKIS, D. Customer clustering using rfm analysis. *Proceedings of the 9th WSEAS international conference on System science and simulation in engineering*, 2005.

CORTES, C.; VAPNIK, V. Support-vector networks. *Machine learning*, Springer, v. 20, p. 273–297, 1995.

DIBIKE, Y. B.; VELICKOV, S.; SOLOMATINE, D. Support vector machines: Review and applications in civil engineering. In: *Proceedings of the 2nd Joint Workshop on Application of AI in Civil Engineering*. [S.l.: s.n.], 2000. p. 215–218.

DUNN, J. C. A fuzzy relative of the isodata process and its use in detecting compact well-separated clusters. *Journal of Cybernetics*, Taylor & Francis, v. 3, n. 3, p. 32–57, 1973.

DUNN, J. C. Well-separated clusters and optimal fuzzy partitions. *Journal of Cybernetics*, Taylor & Francis, v. 4, n. 1, p. 95–104, 1974.

ESTER, M. et al. A density-based algorithm for discovering clusters in large spatial databases with noise. In: *kdd*. [S.l.: s.n.], 1996. v. 96, n. 34, p. 226–231.

FERREIRA, E. V.; ZEVIANI, W. M. Aprendizado não supervisionado. *Universidade Federal do Paraná (UFPR), entre*, 2013.

FORGY, E. W. Cluster analysis of multivariate data: efficiency versus interpretability of classifications. *biometrics*, v. 21, p. 768–769, 1965.

GHOSH, S.; DUBEY, S. K. Comparative analysis of k-means and fuzzy c-means algorithms. *International Journal of Advanced Computer Science and Applications*, Citeseer, v. 4, n. 4, 2013.

HUANG, J.-J. et al. Marketing segmentation using support vector clustering. *Expert Systems with Applications*, Elsevier, v. 32, p. 313–317, 2007.

HUBERT, L.; ARABIE, P. Comparing partitions. *Journal of classification*, Springer, v. 2, p. 193–218, 1985.

IZBICKI, R.; SANTOS, T. M. dos. *Aprendizado de máquina: uma abordagem estatística*. [S.l.]: Rafael Izbicki, 2020.

JOHNSON, S. C. Hierarchical clustering schemes. *Psychometrika*, Springer-Verlag, v. 32, n. 3, p. 241–254, 1967.

KANSAL, T. et al. Customer segmentation using k-means clustering. *International Conference on Computational Techniques, Electronics and Mechanical Systems (CTEMS)*, p. 135–139, 2018.

KHAN, K. et al. Dbscan: Past, present and future. In: IEEE. *The fifth international conference on the applications of digital information and web technologies (ICADIWT 2014)*. [S.l.], 2014. p. 232–238.

KOHONEN, T. The self-organizing map. *Proceedings of the IEEE*, IEEE, v. 78, n. 9, p. 1464–1480, 1990.

MAATEN, L. v. d.; HINTON, G. Visualizing data using t-sne. *Journal of machine learning research*, v. 9, n. Nov, p. 2579–2605, 2008.

MOURÃO-MIRANDA, J. et al. Patient classification as an outlier detection problem: an application of the one-class support vector machine. *Neuroimage*, Elsevier, v. 58, n. 3, p. 793–804, 2011.

PALACIO-NIÑO, J.-O.; BERZAL, F. Evaluation metrics for unsupervised learning algorithms. *arXiv preprint arXiv:1905.05667*, 2019.

PETRUS, J. et al. Soft and hard clustering for abstract scientific paper in indonesian. In: IEEE. *2019 International Conference on Informatics, Multimedia, Cyber and Information System (ICIMCIS)*. [S.l.], 2019. p. 131–136.

PHAM, T. et al. Fast support vector clustering. *Vietnam Journal of Computer Science*, Springer, v. 4, p. 13–21, 2017.

RAJAGOPAL, S. Customer data clustering using data mining technique. *International Journal of Database Management Systems (IJDMS)*, v. 3, p. 125–137, 2011.

ROUSSEEUW, P. J. Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, v. 20, p. 53–65, 1987.

STITSON, M. et al. Theory of support vector machines. *University of London*, v. 117, n. 827, p. 188–191, 1996.

VAPNIK, V.; GOLOWICH, S.; SMOLA, A. Support vector method for function approximation, regression estimation and signal processing. In: MOZER, M.; JORDAN, M.; PETSCHE, T. (Ed.). *Advances in Neural Information Processing Systems*. MIT Press, 1996. v. 9. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/1996/file/4f284803bd0966cc24fa8683a34afc6e-Paper.pdf>.

VESANTO, J.; ALHONIEMI, E. Clustering of the self-organizing map. *IEEE Transactions on neural networks*, Ieee, v. 11, n. 3, p. 586–600, 2000.

WESTON, J. et al. Support vector density estimation. *Advances in Kernel Methods—Support Vector Learning*, Cambridge, MA: MIT Press, p. 293–306, 1999.